1. Srednje vrijednosti.

Srednja vrijednost je konstanta koja ima za cilj na reprezentativan način predstaviti niz varijabilnih podataka numeričkoga niza. Vrste:

1. Aritmetička sredina,

Ona predstavlja jednaki dio vrijednosti numeričkog obilježja koji otpada na jednu jedinicu statističkog skupa.

$$\overline{X} = \frac{\sum_{i=1}^{N} x_i}{N}$$
 ; $i = 1, 2, 3, ..., N$

Aritmetička sredina nalazi se između najmanje i najveće vrijednosti obilježja. Zbroj odstupanja pojedinih vrijednosti obilježja od aritmetičke sredine jednak je nuli: $\sum_{i=0}^{N} (x_i - \overline{x}) = 0$

Zbroj kvadrata odstupanja vrijednosti obilježja pojedinih elemenata statističkog skupa ima minimalnu vrijednost: $\sum_{i=1}^{N} (x_i - \overline{x})^2 \le \sum_{i=1}^{N} (x_i - a)^2$

Vagana (ponderirana) aritmetička sredina

$$\overline{X} = \frac{\sum_{i=1}^{k} f_i \cdot x_i}{\sum_{i=1}^{k} f_i}$$

2.Geometriiska sredina

Geometrijska sredina definira se ovako za negrupirane nizove

$$G = N \prod_{i=1}^{N} X_i$$

Geometrijska sredina uvijek je manja od aritmetičke sredine.

3 Harmoniiska sredina

Harmonijska sredina predstavlja recipročnu vrijednost aritmetičke sredine recipročnih vrijednosti iz kojih se ona izračunava.

$$H = \frac{\sum_{i=1}^{k} f_i}{\sum_{i=1}^{k} \frac{f_i}{x_i}}$$

4.Medijan

Medijan je *pozicijska srednja vrijednost* koja statistički niz dijeli na dva jednaka dijela. Podatke treba poredati od najmanjega prema najvećemu ili obrnuto. Medijan se računa za numeričke i redosljedne nizove.

5.Mod

Mod ili dominanta predstavlja najčešću vrijednost obilježja. Može se računati za sve vrste nizova. Prednost medijana u odnosu na aritmetičku sredinu je u tome što ne reagira na ekstremne vrijednost.

2. Mjere disperzije.

Pod pojmom disperzije podrazumijevamo raspršenost vrijednosti numeričkoga obilježja. Mjere disperzije služe za ocjenjivanje reprezentativnosti srednje vrijednosti obilježja.

Najčešće u uporabi su ove mjere disperzije:

Apsolutne mjere disperzije: raspon varijacije obilježja, prosječno apsolutno odstupanje, varijanca i standardna devijacija,

interkvartil.

Relativne mjere disperzije: koeficijent varijacije, koeficijent kvartilne devijacije

Prosječno apsolutno odstupanje ("Mean Absolute Deviation") dobiva se kao aritmetička sredina apsolutnih vrijednosti odstupanja od aritmetičke sredine vrijednosti obiliežia:

$$MAD = \frac{\sum_{i=1}^{N} \left| X_i - \overline{X} \right|}{N}$$

Varijanca je srednje kvadratno odstupanje numeričkih vrijednosti obilježja od aritmetičke sredine. Standardna devijacija je pozitivni korijen iz varijance i predstavlja apsolutnu mjeru disperzije u prvome stupnju.

Varijanca za negrupirane podatke računa se preko sljedećega izraza:

$$\sigma^{2} = \frac{\sum_{i=1}^{N} (X_{i} - \overline{X})^{2}}{N} \quad \text{ili} \quad \sigma^{2} = \frac{\sum_{i=1}^{N} x_{i}^{2}}{N} - (\overline{x})^{2}$$

Varijanca za grupirane nizove

$$\sigma^{2} = \frac{\sum_{i=1}^{k} f_{i} \cdot (x_{i} - \overline{x})^{2}}{\sum_{i=1}^{k} f_{i}} \quad \text{ili} \quad \sigma^{2} = \frac{\sum_{i=1}^{k} f_{i} \cdot x_{i}^{2}}{\sum_{i=1}^{k} f_{i}} - (\overline{x}^{2})$$

Standardna devijacija je pozitivni korijen iz varijance: $\sigma = +\sqrt{\sigma^2}$ Interkvartil predstavlja apsolutnu mjeru disperzije srednjih 50% jedinica u statističkome skupu. Time interkvartil izbjegava ekstremne vrijednosti obilježja i isključuje 25% najmanjih i 25% najvećih vrijednosti.

$$I_{a} = Q_{2} - Q_{1}$$

Kvartili zajedno s medijanom dijele statistički skup na četiri jednaka dijela. **Koeficijent varijacije** relativna je mjera disperzije:

$$V = \frac{\sigma}{x} \cdot (100)$$

Koeficijent kvartilne devijacije relativna je mjera disperzije srednjih 50% jedinica u statističkome nizu.

$$V_q = rac{Q_3 - Q_1}{Q_3 + Q_1}$$
 Njegova vrijednost kreće se između 0 i 1.

U ZADACIMA još RADILI:

Pearsonov koeficijent asimetrije dobiva se kao omjer trećega centralnoga momenta i standardne devijacije prethodno dignute na treću potenciju.

$$\alpha_3 = \frac{\mu_3}{\sigma^3} \qquad \mu_3 = \frac{\displaystyle\sum_{i=1}^k f_i \cdot (X_i - \overline{X})^3}{\displaystyle\sum_{i=1}^k f_i} \text{ kod negrupiranih: } \mu_3 = \frac{\displaystyle\sum_{i=1}^N (X_i - \overline{X})^3}{N}$$

Kod simetričnih distribucija vrijednost Pearsonovoga koeficijenta asimetrije jednaka je nuli.Kod desnostrane (pozitivne) asimetrije veći je od nule, dok je kod ljevostrane (negativne) asimetrije manji od nule.

U većini slučajeva: $-2 \le \alpha_3 \le +2$

Pearsonova mjera asimetrije definira se na temelju odnosa aritmetičke sredine i moda na sljedeći način:

$$S_k = \frac{\overline{X} - M_o}{\sigma}$$

Kao jedna od karakteristika numeričkih vrijednosti obilježja distribucije može se uvesti još i zaobljenost vrha (kurtoza). U tu svrhu se upotrebljava koeficijent zaobljenosti vrha distribucije sa sljedećim izrazom:

$$\alpha_4 = \frac{\mu_4}{\sigma^4}$$
 $\mu_4 = \frac{\sum_{i=1}^{\kappa} f_i \cdot (x_i - \overline{x})^4}{\sum_{i=1}^{k} f_i}$

3. Pojam vjerojatnosti. Adicijski i multiplikacijski teorem. Bernoullijev zakon velikih brojeva.

Teorija vjerojatnosti čini osnovu statističkoga zaključivanja. Vjerojatnost je spoj filozofijskoga poimanja slučaja i matematike.

Prema klasičnoj definiciji vjerojatnost realizacije slučajnoga događaja A jednaka je omjeru broja (za njega!) povoljnih ishoda i svih mogućih ishoda:

$$P(A) = \frac{m(A)}{n}$$

vjerojatnost je mjera slučaja koja se kreće između 0 i 1

Vjerojatnost da se slučajni događaj (A) **ne realizira** jednaka je omjeru broja za njega nepovoljnih ishoda i broja svih mogućih ishoda:

$$p(\overline{A}) = \frac{n - m(A)}{n}$$
 stoga je: $P(A) + P(\overline{A}) = 1$

Kod vjerojatnosti "a priori" **unaprijed** je poznat broj povoljnih i broj svih mogućih ishoda.

Ukoliko vjerojatnost realizacije slučajnoga događaja A nije poznata unaprijed, može se izračunati tzv. "vjerojatnost a posteriori".

$$P(A) = p \lim_{n \to \infty} \frac{m(A)}{n}$$

Izraz p lim se čita "granična vrijednost po vjerojatnosti" da se razlikuje od limesa u linearnoj algebri. Gornji izraz predstavlja **Bernoullijev zakon velikih brojeva**. Vjerojatnost "a posteriori" jednaka je graničnoj vrijednosti relativne frekvencije kada broj pokusa teži u beskonačnost.

Ako dva slučajna događaja ne mogu nastupiti istodobno, kažemo da se ti događaji međusobno isključuju. Vjerojatnost realizacije jednoga ili drugoga događaja jednaka je zbroju vjerojatnosti realizacije jednoga i vjerojatnosti realizacije drugoga događaja. $P(A \; \text{ili} \; B) = P(A) + P(B)$

Ukoliko se slučajni događaji A i B ne isključuju, tada se vjerojatnost realizacije slučajnoga događaja A ili događaja B dobiva na sljedeći način:

$$P(A \text{ ili } B) = P(A) + P(B) - P(AB)$$

P(AB) predstavlja vjerojatnost da slučajni događaji A i B nastupe istovremeno. Teorem se može poopćiti na više događaja.

Ukoliko se događaji A i B međusobno ne isključuju, i ako vjerojatnost realizacije jednoga događaja ne zavisi o vjerojatnosti realizacije drugoga događaja, tada je vjerojatnost istovremene realizacije događaja A i događaja B jednaka umnošku vjerojatnosti realizacije događaja A i događaja B: $P(A \mid B) = P(A) \cdot P(B)$ Za takove događaje kažemo da su (stohastički) nezavisni.

4. Uvietna vieroiatnost. Bavesov teorem.

Ukoliko je realizacija događaja A uvjetovana prethodnom realizacijom događaja B, radi se o uvjetnoj ili KONDICIONALNOJ vjerojatnosti događaja A.

$$P(A/B) = \frac{P(AB)}{P(B)} \quad , \quad P(B) > 0 \quad \text{odnosno} \quad P(B/A) = \frac{P(AB)}{P(A)} \quad , \quad P(A) > 0$$

Kod nezavisnih događaja vrijedi sljedeće: P(A/B) = P(A)

Bavesov teorem:

Ako se događaj B realizira samo tada kada nastupi jedan od n disjunktnih

događaja A1, A2, ..., An za koje je $\sum_{i=1}^{n} P(A_i) = 1$ onda se vjerojatnost događaja B

dobiva po formuli potpune vjerojatnosti: $P(B) = \sum_{i=1}^{n} P(A_i) \cdot P(B/A_i)$

$$P(A_k/B) = \frac{P(A_k) \cdot P(B/A_k)}{\sum_{i=1}^{n} P(A_i) \cdot P(B/A_i)} \qquad \sum_{i=1}^{n} P(A_i) = 1$$

5. Diskontinuirana slučajna varijabla. Svojstva i teorijske distribucije diskontinuirane slučajne varijable.

Diskontinuirana (ili diskretna) slučajna varijabla je takova varijabla koja može poprimiti najviše prebrojivo beskonačno mnogo vrijednosti s određenom vjerojatnošću: $P(x_1), P(x_2),...$

pri čemu mora biti:

$$\sum_{i=1}^{\infty} P(x_i) = 1 \quad i \quad P(x_i) \ge 0 \quad \forall i$$

Uređeni skup parova: $\{x_i, P(x_i)\}, i = 1, 2, 3, ...$

naziva se distribucija slučajne varijable X. Zakon po kojem svakoj vrijednosti slučajne varijable X pripada vjerojatnost P(xi) naziva se **zakon vjerojatnosti** slučajne varijable X.

Funkcija distribucije slučajne varijable X predstavlja vjerojatnost da slučajna varijabla X ne premaši neku određenu vrijednost:

$$F(x_k) = \sum_{i=1}^{k} P(x_i) = P(X \le x_k)$$

Očekivanje diskontinuirane slučajne varijable jednako je zbroju umnožaka vrijednosti varijable X i odgovarajućih vjerojatnosti:

$$E(X) = \sum_{i=1}^{\infty} x_i \cdot p(x_i) = \mu$$

Varijanca diskontinuirane slučajne varijable X je očekivanje kvadratnoga odstupanja vrijednosti varijable X od njenoga očekivanja:

$$V(X) = E(X - \mu)^2$$
 odnosno $V(X) = E(X^2) - [E(X)]^2$

Teorijske distribucije diskontinuirane slučajne varijable Binomna distribucija

Ako je vjerojatnost da nastupi neki slučajni događaj **poznata i uvijek ista tijekom izvođenja pokusa** može se izračunati vjerojatnost da se slučajna varijabla *X* realizira *x* puta u *n* pokusa. U tome slučaju kažemo da se diskontinuirana slučajna varijabla *X* ravna prema binomnoj distribuciji. Binomna distribucija ima sljedeći zakon vjerojatnosti:

$$P(X = x) = \binom{n}{x} \cdot p^x \cdot q^{n-x} \quad x = 0,1,2,3,...,n$$

n = broj pokusa,

x = broi povolinih ishoda u n pokusa.

p = vjerojatnost realizacije slučajnoga događaja,

n - x = broi nepovolinih ishoda u n pokusa

$$(E(x) = n \cdot p, \quad \sigma^2 = n \cdot p \cdot q, \quad \alpha_3 = \frac{q - p}{\sqrt{n \cdot p \cdot q}} \qquad \alpha_4 = 3 + \frac{1 - 6 \cdot p \cdot q}{n \cdot p \cdot q})$$

Poissonova Distribucija

Ako je vjerojatnost slučajnoga događaja veoma malena i konstantna tijekom izvođenja pokusa, umjesto binomne distribucije može se koristiti Poissonova

$$P(X = x) = \frac{(np)^x \cdot e^{-np}}{x!}$$
 $x = 0,1,2,3,...\infty$

$$p(X = x) = \frac{\mu^x \cdot e^{-\mu}}{x!}$$
 $x = 0,1,2,3,...,\infty$

$$p(X = x) = \frac{\mu^{x} \cdot e^{-\mu}}{x!} \qquad x = 0, 1, 2, 3, ..., \infty$$

$$E(X) = \mu \quad V(X) = \mu \quad \alpha_{3} = \frac{1}{\sqrt{\mu}} \quad \alpha_{4} = 3 + \frac{1}{\mu}$$

$$P(X=x) = \frac{\binom{M}{x} \cdot \binom{N-M}{n-x}}{\binom{N}{n}} , \quad x = 0,1,2,...,n$$

$$E(X) = n \cdot \frac{M}{N} \qquad V(X) = n \, \cdot \, \frac{M}{N} \, \cdot \, \frac{N-M}{N} \, \cdot \, \frac{N-n}{N-1}$$

$$P(X = x_i) = \frac{1}{n}, \quad \forall x_i \in R_x$$

$$y_1, y_2, y_3, ..., y_m$$

$$P(X = x_i, Y = y_j) = P(x_i, y_j)$$

Budući da se radi o distribuciji vjerojatnosti, moraju biti zadovoljeni sljedeći uvjeti:

$$\sum_{i=1}^{n} \sum_{j=1}^{m} P(x_i, y_j) = 1 \qquad P(x_i y_j) \ge 0$$

****za zadatke triba znat (primjer):

$$E(X/Y = 1) = \sum_{i} x_{i} \cdot P(x_{i}/y = 1)$$

$$V(X/Y = 1) = \sum_{i} x_{i}^{2} \cdot P(x_{i}/y = 1) - [E(X/Y = 1)]^{2}$$

Skup svih uređenih parova $\{(x_i, y_j); P(x_i, y_j)\}$ sačinjava dvodimenzionalnu distribuciju slučajne varijable (X, Y).

Marginalne Distribucije Diskontinuirane Slučajne Varijable

Kod marginalnih distribucija primjenjuje se adicijski teorem. Traži se vjerojatnost da slučajna varijabla X poprimi neku vrijednost Xi bez obzira na to koju će vrijednost poprimiti slučajna varijabla Yj. Slično tomu, marginalna distribucija slučajne varijable Y predstavlja vjerojatnosti da varijabla Y poprimi vrijednost Yj bez obzira koju vrijednost poprima slučajna varijabla X.

$$P(x_i) = \sum_{j=1}^{m} P(x_i, y_j)$$
 $P(y_j) = \sum_{i=1}^{n} P(x_i, y_j)$

Vjerojatnost da slučajna varijabla X poprimi neku vrijednost xi **pod uvjetom** da je varijabla Y poprimila neku vrijednost yj naziva se uvjetnom ili kondicionalnom distribucijom vjerojatnosti:

$$P(x_i/y_j) = \frac{P(x_i, y_j)}{\sum_{j=1}^{m} P(x_i, y_j)} = \frac{P(x_i, y_j)}{P(y_j)}$$

7. Kontinuirana slučajna varijabla. Svojstva i teorijske distribucije kontinuirane slučajne varijable.

Kontinuirana slučajna varijabla X može poprimiti neprebrojivo beskonačno mnogo vrijednosti. Kod kontinuiranih slučajnih varijabli ne računa se vjerojatnost u određenoj točki, nego nad određenim intervalom vrijednosti slučajne varijable X. Vjerojatnost da će neka kontinuirana slučajna varijabla X poprimiti neku određenu vrijednost x jednaka je nuli, ali to ne znači i nemogući događaj.

Kod kontinuirane slučajne varijable umjesto P(X) upotrebljavamo f(X). Funkcija vjerojatnosti f(X) nije vjerojatnost, ali je tom funkcijom određena vjerojatnost što pripada svakom intervalu (x_1,x_2)

Funkcija vjerojatnosti (naziva se i funkcija gustoće vjerojatnosti) kontinuirane slučajne varijable X ima sljedeća svojstva:

$$f(x) \ge 0 \quad \forall x$$

Površina ispod krivulje vjerojatnosti jednaka je 1

$$\int_{-\infty}^{+\infty} f(x)dx = 1 \qquad \int_{x_1}^{x_2} f(x)dx = P\{x_1 < X \le x_2\} \qquad x_2 > x_1$$

Funkcija distribucije kontinuirane slučajne varijable X je sljedeća:

$$F(x) = \int_{-\infty}^{x} f(x)dx \qquad \frac{dF(x)}{dx} = f(x)$$

F(x) predstavlja vjerojatnost da slučajna varijabla X ne premaši neku unaprijed zadanu vrijednost x. U empirijskoj statistici ta funkcija predstavlja kumulativni niz "manje od".

Očekivanje i varijanca kontinuirane slučajne varijable:

$$E(X) = \int_{-\infty}^{+\infty} x \cdot f(x) dx = \mu \qquad V(x) = \int_{-\infty}^{+\infty} (x - \mu)^2 \cdot f(x) dx = \int_{-\infty}^{+\infty} x^2 \cdot f(x) dx - \mu^2$$

TEORIJSKE DISTRIBUCIJE

- **Normalna distribucija** je najvažnija distribucija u statističkoj teoriji. Funkcija gustoće vjerojatnosti normalne distribucije je sljedeća:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}}e^{-\frac{1}{2}(\frac{x-\mu}{\sigma})^2} \quad x \in <-\infty, +\infty>$$

Parametri normalne distribucije su njeno očekivanje μ i varijanca σ^2 .

$$Z = \frac{x - \mu}{\sigma}$$

Ovdje se radi o normalnoj distribuciji N(0;1) koju nazivamo standardiziranom ili jediničnom normalnom distribucijom s očekivanjem koje je jednako nuli, a varijancom jednakom jedinici.

-Studentova distribucija

Studentova distribucija česta je u primjenama u procjeni parametara i u testiranju hipoteza na osnovu uzorka. Njezin oblik ovisi o broju stupnjeva slobode v. Područje vrijednosti varijable t je interval $(-\infty; +\infty)$. Studentova distribucija je simetrična s obzirom na t = 0. Spljoštenija je od normalne distribucije. Ukoliko $v \to \infty$ Studentova distribucija teži jediničnoj normalnoj distribuciji. Ako je Z varijabla jedinične normalne distribucije N(0;1), a varijabla gama distribucije s brojem stupnjeva slobode v, onda je:

$$t = \frac{z}{\sqrt{\frac{\chi^2}{v}}}$$
 varijabla Studentove distribucije s brojem stupnjeva slobode v.

-HI-kvadrat distribucija

Ako su X1, X2, X3, ..., Xn nezavisne normalne varijable koje imaju jednaka očekivanja, $E(X1) = = E(Xn) = \mu$ i jednake varijance V(X1) = = V(Xn) = tada je:

$$\chi^2 = \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma}\right)^2$$
 gama varijabla sa stupnjem slobode $v = n$.

slobode. Ako su
$$\chi_1^2$$
 i χ_2^2 nezavisne χ_2^2 razdiobe sa stupnjevima s tada varijabla:
$$F = \frac{\chi_1^2}{\chi_2^2}$$
 pripada F-distribuciji sa stupnjevima slobode v1 i v2.

$$f = \frac{n}{N}$$
 n = broj jedinica u uzorku, N = broj jedinica u osnovnome skupu

$$\Pr\left\{\frac{\hat{X}}{X} - z \cdot Se(\bar{X}) < \overline{X} < \frac{\hat{X}}{X} + z \cdot Se(\bar{X})\right\} = 1 - \alpha$$

$$Se(\hat{X}) = \frac{\hat{\sigma}}{\sqrt{n}}$$

$$Se(\hat{X}) = \frac{\hat{\sigma}}{\sqrt{n}} \cdot \sqrt{\frac{N-n}{N-1}}$$
 Za male uzorke (n < 30) koristimo "t" iz Studentove

$$n' = \left[\frac{z \cdot \sigma}{greska} \right]^2$$

Korekcija za konačne osnovne skupove gdje je frakcija manja od 0.05

$$n = \frac{n'}{1 + \frac{n'}{N}}$$

10. Procjena proporcije (relativne frekvencije) na osnovu uzorka.

$$\Pr\left\{ \stackrel{\wedge}{p} - z \cdot Se(p) < P < \stackrel{\wedge}{p} + z \cdot Se(p) \right\} = 1 - \alpha$$

Prociena proporcije na osnovu uzorka nepristrana je

Pri tomu se standardna grješka procjene proporcije dobiva ovako:

$$Se(p) = \sqrt{\frac{p \cdot q}{n}}$$
 ako je n > 30 jedinica $Se(p) = \sqrt{\frac{p \cdot q}{n-1}}$ ako je n < 30 jedinica

p = m / n; q = (1-p)

Korekcija za konačne skupove je ista kao i kod procjene aritmetičke sredine osnovnoga skupa.

11. Prociena varijance na osnovu uzorka.

Procjena varijance na osnovu uzorka je pristrana. Sampling distribucija varijanci ima oblik Hi-kvadrat distribucije. Nepristrana ocjena varijance osnovnoga skupa može se dobiti ovako:

$$s^2 = \hat{\sigma} \cdot \frac{n}{n-1}$$
 s² predstavlja nepristranu procjenu varijance osnovnoga skupa

Intervalna prociena varijance osnovnoga skupa

$$\Pr\left\{\frac{n \cdot s^2}{\chi_{\alpha/2}^2} < \sigma^2 < \frac{n \cdot s^2}{\chi_{1-\alpha/2}^2}\right\} = 1 - \alpha$$

U koliko veličina uzorka prelazi 30 jedinica Hi-kvadrat distribucija distribucija može se aproksimirati pomoću normalne distribucije. Tada se vrijednosti Hi-kvadrata ogu dobiti pomoću slijedeće formule:

$$\chi_{\alpha/2}^2 = \frac{1}{2} \left(z_{\frac{1-\alpha}{2}} + \sqrt{2 \cdot \nu - 1} \right)^2 \quad \chi_{1-\alpha/2}^2 = \frac{1}{2} \left(-z_{\frac{1-\alpha}{2}} + \sqrt{2 \cdot \nu - 1} \right)^2$$