

1. Srednje vrijednosti.

Srednja vrijednost je konstanta koja ima za cilj na reprezentativan način predstaviti niz varijabilnih podataka numeričkoga niza. Vrste:

1. Aritmetička sredina,

Ona predstavlja jednaki dio vrijednosti numeričkog obilježja koji otpada na jednu jedinicu statističkog skupa.

$$\bar{X} = \frac{\sum_{i=1}^N x_i}{N} \quad ; \quad i = 1, 2, 3, \dots, N$$

Aritmetička sredina nalazi se između najmanje i najveće vrijednosti obilježja.

Zbroj odstupanja pojedinih vrijednosti obilježja od aritmetičke sredine jednak je

nuli: $\sum_{i=1}^N (x_i - \bar{x}) = 0$

Zbroj kvadrata odstupanja vrijednosti obilježja pojedinih elemenata statističkog

skupa ima minimalnu vrijednost: $\sum_{i=1}^N (x_i - \bar{x})^2 \leq \sum_{i=1}^N (x_i - a)^2$

Vagana (ponderirana) aritmetička sredina

$$\bar{X} = \frac{\sum_{i=1}^k f_i \cdot x_i}{\sum_{i=1}^k f_i}$$

2. Geometrijska sredina

Geometrijska sredina definira se ovako za negrupirane nizove:

$$G = \sqrt[N]{\prod_{i=1}^N X_i}$$

Geometrijska sredina uvijek je manja od aritmetičke sredine.

3. Harmonijska sredina,

Harmonijska sredina predstavlja recipročnu vrijednost aritmetičke sredine recipročnih vrijednosti iz kojih se ona izračunava.

$$H = \frac{\sum_{i=1}^k f_i}{\sum_{i=1}^k \frac{f_i}{x_i}}$$

4. Medijan,

Medijan je pozicijska srednja vrijednost koja statistički niz dijeli na dva jednaka dijela. Podatke treba poredati od najmanjega prema najvećemu ili obrnuto. Medijan se računa za numeričke i redosljedne nizove.

5. Mod.

Mod ili dominanta predstavlja najčešću vrijednost obilježja. Može se računati za sve vrste nizova. Prednost medijana u odnosu na aritmetičku sredinu je u tome što ne reagira na ekstremne vrijednosti.

2. Mjere disperzije.

Pod pojmom disperzije podrazumijevamo raspršenost vrijednosti numeričkoga obilježja. Mjere disperzije služe za ocjenjivanje reprezentativnosti srednje vrijednosti obilježja.

Najčešće u uporabi su ove mjere disperzije:

Apsolutne mjere disperzije: raspon varijacije obilježja, prosječno apsolutno odstupanje, varijanca i standardna devijacija, interkvartil.

Relativne mjere disperzije: koeficijent varijacije, koeficijent kvartilne devijacije.

Prosječno apsolutno odstupanje ("Mean Absolute Deviation") dobiva se kao aritmetička sredina apsolutnih vrijednosti odstupanja od aritmetičke sredine vrijednosti obilježja:

$$MAD = \frac{\sum_{i=1}^N |X_i - \bar{X}|}{N}$$

Varijanca je srednje kvadratno odstupanje numeričkih vrijednosti obilježja od aritmetičke sredine. **Standardna devijacija** je pozitivni korijen iz varijance i predstavlja apsolutnu mjeru disperzije u prvome stupnju.

Varijanca za negrupirane podatke računa se preko sljedećega izraza:

$$\sigma^2 = \frac{\sum_{i=1}^N (X_i - \bar{X})^2}{N} \quad \text{ili} \quad \sigma^2 = \frac{\sum_{i=1}^N x_i^2}{N} - (\bar{x})^2$$

Varijanca za grupirane nizove:

$$\sigma^2 = \frac{\sum_{i=1}^k f_i \cdot (x_i - \bar{x})^2}{\sum_{i=1}^k f_i} \quad \text{ili} \quad \sigma^2 = \frac{\sum_{i=1}^k f_i \cdot x_i^2}{\sum_{i=1}^k f_i} - (\bar{x})^2$$

Standardna devijacija je pozitivni korijen iz varijance: $\sigma = +\sqrt{\sigma^2}$

Interkvartil predstavlja apsolutnu mjeru disperzije srednjih 50% jedinica u statističkome skupu. Time interkvartil izbjegava ekstremne vrijednosti obilježja i isključuje 25% najmanjih i 25% najvećih vrijednosti.

$$I_q = Q_3 - Q_1$$

Kvartili zajedno s medijanom dijele statistički skup na četiri jednaka dijela.

Koeficijent varijacije relativna je mjera disperzije:

$$V = \frac{\sigma}{\bar{x}} \cdot (100)$$

Koeficijent kvartilne devijacije relativna je mjera disperzije srednjih 50% jedinica u statističkom nizu.

$$V_q = \frac{Q_3 - Q_1}{Q_3 + Q_1} \quad \text{Njegova vrijednost kreće se između 0 i 1.}$$

U ZADACIMA još RADILI:

Pearsonov koeficijent asimetrije dobiva se kao omjer trećega centralnoga momenta i standardne devijacije prethodno dignute na treću potenciju.

$$\alpha_3 = \frac{\mu_3}{\sigma^3} \quad \mu_3 = \frac{\sum_{i=1}^k f_i \cdot (X_i - \bar{X})^3}{\sum_{i=1}^k f_i} \quad \text{kod negrupiranih: } \mu_3 = \frac{\sum_{i=1}^N (X_i - \bar{X})^3}{N}$$

Kod simetričnih distribucija vrijednost Pearsonovoga koeficijenta asimetrije jednaka je nuli. Kod desnostrane (pozitivne) asimetrije veći je od nule, dok je kod lijevostrane (negativne) asimetrije manji od nule.

U većini slučajeva: $-2 \leq \alpha_3 \leq +2$

Pearsonova mjera asimetrije definira se na temelju odnosa aritmetičke sredine i moda na sljedeći način:

$$S_k = \frac{\bar{X} - M_o}{\sigma}$$

Kao jedna od karakteristika numeričkih vrijednosti obilježja distribucije može se uvesti još i zaobljenost vrha (kurtoza). U tu svrhu se upotrebljava koeficijent zaobljenosti vrha distribucije sa sljedećim izrazom:

$$\alpha_4 = \frac{\mu_4}{\sigma^4} \quad \mu_4 = \frac{\sum_{i=1}^k f_i \cdot (x_i - \bar{x})^4}{\sum_{i=1}^k f_i}$$

3. Pojam vjerojatnosti. Adicijski i multiplikacijski teorem. Bernoullijev zakon velikih brojeva.

Teorija vjerojatnosti čini osnovu statističkoga zaključivanja. Vjerojatnost je spoj filozofijskoga poimanja slučaja i matematike.

Prema klasičnoj definiciji vjerojatnost realizacije slučajnoga događaja A jednaka je omjeru broja (za njega!) povoljnih ishoda i svih mogućih ishoda:

$$P(A) = \frac{m(A)}{n}$$

vjerojatnost je mjera slučaja koja se kreće između 0 i 1.

Vjerojatnost da se slučajni događaj (A) **ne realizira** jednaka je omjeru broja za njega nepovoljnih ishoda i broja svih mogućih ishoda:

$$p(\bar{A}) = \frac{n - m(A)}{n} \quad \text{stoga je: } P(A) + P(\bar{A}) = 1$$

Kod vjerojatnosti "a priori" **unaprijed** je poznat broj povoljnih i broj svih mogućih ishoda.

Ukoliko vjerojatnost realizacije slučajnoga događaja A nije poznata unaprijed, može se izračunati tzv. "vjerojatnost a posteriori".

$$P(A) = p \lim_{n \rightarrow \infty} \frac{m(A)}{n}$$

Izraz p lim se čita "granična vrijednost po vjerojatnosti" da se razlikuje od limesa u linearnoj algebri. Gornji izraz predstavlja **Bernoullijev zakon velikih brojeva**. Vjerojatnost "a posteriori" jednaka je graničnoj vrijednosti relativne frekvencije kada broj pokusa teži u beskonačnost.

Ako dva slučajna događaja ne mogu nastupiti istodobno, kažemo da se ti događaji međusobno isključuju. Vjerojatnost realizacije jednoga ili drugoga događaja jednaka je zbroju vjerojatnosti realizacije jednoga i vjerojatnosti realizacije drugoga događaja. $P(A \text{ ili } B) = P(A) + P(B)$

Ukoliko se slučajni događaji A i B ne isključuju, tada se vjerojatnost realizacije slučajnoga događaja A ili događaja B dobiva na sljedeći način:

$$P(A \text{ ili } B) = P(A) + P(B) - P(AB)$$

$P(AB)$ predstavlja vjerojatnost da slučajni događaji A i B nastupe istovremeno. Teorem se može poopćiti na više događaja.

Ukoliko se događaji A i B međusobno ne isključuju, i ako vjerojatnost realizacije jednoga događaja ne zavisi o vjerojatnosti realizacije drugoga događaja, tada je vjerojatnost istovremene realizacije događaja A i događaja B jednaka umnošku vjerojatnosti realizacije događaja A i događaja B: $P(A \text{ i } B) = P(A) \cdot P(B)$
Za takove događaje kažemo da su (stohastički) nezavisni.

4. Uvjetna vjerojatnost. Bayesov teorem.

Ukoliko je realizacija događaja A uvjetovana prethodnom realizacijom događaja B, radi se o uvjetnoj ili KONDICIONALNOJ vjerojatnosti događaja A.

$$P(A/B) = \frac{P(AB)}{P(B)}, \quad P(B) > 0 \quad \text{odnosno} \quad P(B/A) = \frac{P(AB)}{P(A)}, \quad P(A) > 0$$

Kod nezavisnih događaja vrijedi sljedeće: $P(A/B) = P(A)$

Bayesov teorem:

Ako se događaj B realizira samo tada kada nastupi jedan od n disjunktih

događaja A_1, A_2, \dots, A_n za koje je $\sum_{i=1}^n P(A_i) = 1$ onda se vjerojatnost događaja B

dobiva po formuli potpune vjerojatnosti: $P(B) = \sum_{i=1}^n P(A_i) \cdot P(B/A_i)$

$$P(A_k/B) = \frac{P(A_k) \cdot P(B/A_k)}{\sum_{i=1}^n P(A_i) \cdot P(B/A_i)} \quad \sum_{i=1}^n P(A_i) = 1$$

5. Diskontinuirana slučajna varijabla. Svojstva i teorijske distribucije diskontinuirane slučajne varijable.

Diskontinuirana (ili diskretna) slučajna varijabla je takova varijabla koja može poprimiti najviše prebrojivo beskonačno mnogo vrijednosti s određenom vjerojatnošću: $P(x_1), P(x_2), \dots$

pri čemu mora biti:

$$\sum_{i=1}^{\infty} P(x_i) = 1 \quad \text{i} \quad P(x_i) \geq 0 \quad \forall i$$

Uređeni skup parova: $\{x_i, P(x_i)\}$, $i = 1, 2, 3, \dots$

naziva se distribucija slučajne varijable X. Zakon po kojem svakoj vrijednosti slučajne varijable X pripada vjerojatnost $P(x_i)$ naziva se **zakon vjerojatnosti** slučajne varijable X.

Funkcija distribucije slučajne varijable X predstavlja vjerojatnost da slučajna varijabla X ne premaši neku određenu vrijednost:

$$F(x_k) = \sum_{i=1}^k P(x_i) = P(X \leq x_k)$$

Očekivanje diskontinuirane slučajne varijable jednako je zbroju umnožaka vrijednosti varijable X i odgovarajućih vjerojatnosti:

$$E(X) = \sum_{i=1}^{\infty} x_i \cdot p(x_i) = \mu$$

Varijanca diskontinuirane slučajne varijable X je očekivanje kvadratnoga odstupanja vrijednosti varijable X od njenoga očekivanja:

$$V(X) = E(X - \mu)^2 \text{ odnosno } V(X) = E(X^2) - [E(X)]^2$$

- Teorijske distribucije diskontinuirane slučajne varijable

Binomna distribucija

Ako je vjerojatnost da nastupi neki slučajni događaj **poznata i uvijek ista tijekom izvođenja pokusa** može se izračunati vjerojatnost da se slučajna varijabla X realizira x puta u n pokusa. U tome slučaju kažemo da se diskontinuirana slučajna varijabla X ravna prema binomnoj distribuciji. Binomna distribucija ima sljedeći zakon vjerojatnosti:

$$P(X = x) = \binom{n}{x} \cdot p^x \cdot q^{n-x} \quad x = 0, 1, 2, 3, \dots, n$$

n = broj pokusa,

x = broj povoljnih ishoda u n pokusa,

p = vjerojatnost realizacije slučajnoga događaja,

n - x = broj nepovoljnih ishoda u n pokusa.

$$(E(x) = n \cdot p, \quad \sigma^2 = n \cdot p \cdot q, \quad \alpha_3 = \frac{q - p}{\sqrt{n \cdot p \cdot q}} \quad \alpha_4 = 3 + \frac{1 - 6 \cdot p \cdot q}{n \cdot p \cdot q})$$

Poissonova Distribucija

Ako je vjerojatnost slučajnoga događaja veoma malena i konstantna tijekom izvođenja pokusa, umjesto binomne distribucije može se koristiti Poissonova

distribucija. U tome slučaju broj pokusa raste u beskonačnost, ali očekivana vrijednost ostaje konstantna. Što je vrijednost od n veća, a vrijednost od p manja, to je aproksimacija bolja. Izraz za Poissonovu distribuciju je sljedeći:

$$P(X = x) = \frac{(np)^x \cdot e^{-np}}{x!} \quad x = 0, 1, 2, 3, \dots, \infty$$

odnosno, s obzirom da je funkcija poprima oblik:

$$p(X = x) = \frac{\mu^x \cdot e^{-\mu}}{x!} \quad x = 0, 1, 2, 3, \dots, \infty$$

$$E(X) = \mu \quad V(X) = \mu \quad \alpha_3 = \frac{1}{\sqrt{\mu}} \quad \alpha_4 = 3 + \frac{1}{\mu}$$

Hipergeometrijska Distribucija

Osnovni skup sastoji se iz dva dijela: skup elemenata koji imaju neko obilježje A i skup elemenata koji to obilježje nemaju. U uzorak se bira određeni broj elemenata osnovnoga skupa. Slučajna varijabla je broj jedinica u uzorku koje imaju određeno obilježje A. Ukoliko se jedinice osnovnoga skupa, koje su jednom uzete u uzorak ne vraćaju ponovno u osnovni skup, radi se o hipergeometrijskoj distribuciji:

$$P(X = x) = \frac{\binom{M}{x} \cdot \binom{N-M}{n-x}}{\binom{N}{n}}, \quad x = 0, 1, 2, \dots, n$$

$P(X)$ = zakon vjerojatnosti slučajne varijable X ,

M = broj elemenata u osnovnom skupu s obilježjem A,

$N - M$ = broj elemenata u osnovnom skupu koji nemaju obilježje A,

$n - x$ = broj elemenata u uzorku koji nemaju obilježje A,

N = broj elemenata u osnovnom skupu,

n = broj elemenata u uzorku,

x = broj elemenata u uzorku koji imaju obilježje A.

$$E(X) = n \cdot \frac{M}{N} \quad V(X) = n \cdot \frac{M}{N} \cdot \frac{N-M}{N} \cdot \frac{N-n}{N-1}$$

Jednolika Distribucija

Ako slučajna varijabla X poprima s istom vjerojatnošću bilo koju od n vrijednosti, kažemo da X ima jednoliku distribuciju:

$$P(X = x_i) = \frac{1}{n}, \quad \forall x_i \in R_x$$

6. Dvodimenzionalna distribucija vjerojatnosti. Marginalna distribucija vjerojatnosti.

Diskontinuirana slučajna varijabla X može poprimiti vrijednosti $x_1, x_2, x_3, \dots, x_k$, dok diskontinuirana slučajna varijabla Y može istovremeno poprimiti vrijednosti

$y_1, y_2, y_3, \dots, y_m$.

Vjerojatnost da slučajna varijabla X poprimi vrijednost x_i , a istovremeno slučajna varijabla Y poprimi vrijednost y_j označava se ovako:

$$P(X = x_i, Y = y_j) = P(x_i, y_j)$$

Budući da se radi o distribuciji vjerojatnosti, moraju biti zadovoljeni sljedeći uvjeti:

$$\sum_{i=1}^n \sum_{j=1}^m P(x_i, y_j) = 1 \quad P(x_i, y_j) \geq 0$$

****za zadatke treba znat (primjer):

$$E(X/Y=1) = \sum_i x_i \cdot P(x_i/y=1)$$

$$V(X/Y=1) = \sum_i x_i^2 \cdot P(x_i/y=1) - [E(X/Y=1)]^2$$

Skup svih uređenih parova $\{(x_i, y_j); P(x_i, y_j)\}$ sačinjava dvodimenzionalnu distribuciju slučajne varijable (X,Y).

Marginalne Distribucije Diskontinuirane Slučajne Varijable

Kod marginalnih distribucija primjenjuje se adicijski teorem. Traži se vjerojatnost da slučajna varijabla X poprimi neku vrijednost x_i bez obzira na to koju će vrijednost poprimiti slučajna varijabla Yj. Slično tomu, marginalna distribucija slučajne varijable Y predstavlja vjerojatnosti da varijabla Y poprimi vrijednost Yj bez obzira koju vrijednost poprima slučajna varijabla X.

$$P(x_i) = \sum_{j=1}^m P(x_i, y_j) \quad P(y_j) = \sum_{i=1}^n P(x_i, y_j)$$

Vjerojatnost da slučajna varijabla X poprimi neku vrijednost x_i **pod uvjetom** da je varijabla Y poprimila neku vrijednost y_j naziva se uvjetnom ili kondicionalnom distribucijom vjerojatnosti:

$$P(x_i/y_j) = \frac{P(x_i, y_j)}{\sum_{j=1}^m P(x_i, y_j)} = \frac{P(x_i, y_j)}{P(y_j)}$$

7. Kontinuirana slučajna varijabla. Svojstva i teorijske distribucije kontinuirane slučajne varijable.

Kontinuirana slučajna varijabla X može poprimiti neprebrojivo beskonačno mnogo vrijednosti. Kod kontinuiranih slučajnih varijabli ne računa se vjerojatnost u određenoj točki, nego nad određenim intervalom vrijednosti slučajne varijable X. Vjerojatnost da će neka kontinuirana slučajna varijabla X poprimiti neku određenu vrijednost x jednaka je nuli, ali to ne znači i nemogući događaj.

Kod kontinuirane slučajne varijable umjesto $P(X)$ upotrebljavamo $f(X)$. Funkcija vjerojatnosti $f(X)$ nije vjerojatnost, ali je tom funkcijom određena vjerojatnost što pripada svakom intervalu (x_1, x_2)

Funkcija vjerojatnosti (naziva se i funkcija gustoće vjerojatnosti) kontinuirane slučajne varijable X ima sljedeća svojstva:

$$f(x) \geq 0 \quad \forall x$$

Površina ispod krivulje vjerojatnosti jednaka je 1:

$$\int_{-\infty}^{+\infty} f(x) dx = 1 \quad \int_{x_1}^{x_2} f(x) dx = P\{x_1 < X \leq x_2\} \quad x_2 > x_1$$

Funkcija distribucije kontinuirane slučajne varijable X je sljedeća:

$$F(x) = \int_{-\infty}^x f(x)dx \quad \frac{dF(x)}{dx} = f(x)$$

F(x) predstavlja vjerojatnost da slučajna varijabla X ne premaši neku unaprijed zadanu vrijednost x. U empirijskoj statistici ta funkcija predstavlja kumulativni niz "manje od".

Očekivanje i varijanca kontinuirane slučajne varijable:

$$E(X) = \int_{-\infty}^{+\infty} x \cdot f(x)dx = \mu \quad V(x) = \int_{-\infty}^{+\infty} (x - \mu)^2 \cdot f(x)dx = \int_{-\infty}^{+\infty} x^2 \cdot f(x)dx - \mu^2$$

TEORIJSKE DISTRIBUCIJE

- **Normalna distribucija** je najvažnija distribucija u statističkoj teoriji. Funkcija gustoće vjerojatnosti normalne distribucije je sljedeća:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} \quad x \in (-\infty, +\infty)$$

Parametri normalne distribucije su njeno očekivanje μ i varijanca σ^2 .

$$Z = \frac{x - \mu}{\sigma}$$

Ovdje se radi o normalnoj distribuciji $N(0;1)$ koju nazivamo standardiziranom ili jediničnom normalnom distribucijom s očekivanjem koje je jednako nuli, a varijancom jednakom jedinici.

-Studentova distribucija

Studentova distribucija česta je u primjenama u procjeni parametara i u testiranju hipoteza na osnovu uzorka. Njezin oblik ovisi o broju stupnjeva slobode ν .

Područje vrijednosti varijable t je interval $(-\infty; +\infty)$. Studentova distribucija je simetrična s obzirom na $t = 0$. Spljoštenija je od normalne distribucije. Ukoliko $\nu \rightarrow \infty$ Studentova distribucija teži jediničnoj normalnoj distribuciji.

Ako je Z varijabla jedinične normalne distribucije $N(0;1)$, a varijabla gama distribucije s brojem stupnjeva slobode ν , onda je:

$$t = \frac{z}{\sqrt{\frac{\chi^2}{\nu}}} \text{ varijabla Studentove distribucije s brojem stupnjeva slobode } \nu.$$

-HI-kvadrat distribucija

Ako su $X_1, X_2, X_3, \dots, X_n$ nezavisne normalne varijable koje imaju jednaka očekivanja, $E(X_1) = \dots = E(X_n) = \mu$ i jednake varijance $V(X_1) = \dots = V(X_n) = \sigma^2$, tada je:

$$\chi^2 = \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma} \right)^2 \text{ gama varijabla sa stupnjem slobode } \nu = n.$$

-F-distribucija

F- distribucija je određena s dva parametra ν_1 i ν_2 koji predstavljaju stupnjeve slobode. Ako su χ_1^2 i χ_2^2 nezavisne χ^2 razdiobe sa stupnjevima slobode ν_1 i ν_2 tada varijabla:

$$F = \frac{\chi_1^2 / \nu_1}{\chi_2^2 / \nu_2} \text{ pripada F-distribuciji sa stupnjevima slobode } \nu_1 \text{ i } \nu_2.$$

8. Metoda uzoraka. Pristranost procjene na osnovu uzoraka. Nabrojite sve vrste grješaka koje se javljaju kod rada s uzorcima.

Uzorak predstavlja podskup osnovnoga statističkog skupa koji se uzima u svrhu ispitivanja obilježja elemenata osnovnoga skupa. Da bi tu svrhu uzorak mogao ispuniti, potrebno je da bude reprezentativan i da je izbor jedinica izvršen na slučajnan način. Da bi se postigla slučajnost izbora jedinica u uzorak, najčešće se upotrebljavaju tablice slučajnih brojeva.

Frakcija odabiranja predstavlja omjer broja jedinica u uzorku i broja jedinica u osnovnome skupu:

$$f = \frac{n}{N} \quad n = \text{broj jedinica u uzorku}, \quad N = \text{broj jedinica u osnovnome skupu}$$

9. Procjena aritmetičke sredine na osnovu uzorka.

Procjena aritmetičke sredine na osnovu uzorka naziva se točkastom procjenom aritmetičke sredine osnovnoga skupa. Da bi se dobila intervalna procjena aritmetičke sredine, potrebno je u račun uzeti varijabilitet jedinica u osnovnome skupu (izražen preko varijance osnovnoga skupa ili njene ocjene pomoću uzorka) i veličinu uzorka.

Intervalna procjena aritmetičke sredine dobiva se ovako:

$$\Pr \left\{ \bar{X} - z \cdot Se(\bar{x}) < \bar{X} < \bar{X} + z \cdot Se(\bar{x}) \right\} = 1 - \alpha$$

$1-\alpha$ naziva se intervalom povjerenja.

Standardna greška:

$$Se(\bar{X}) = \frac{\hat{\sigma}}{\sqrt{n}}$$

odnosno za konačne skupove:

$$Se(\bar{X}) = \frac{\hat{\sigma}}{\sqrt{n}} \cdot \sqrt{\frac{N-n}{N-1}} \text{ Za male uzorke (} n < 30 \text{) koristimo "t" iz Studentove}$$

Određivanje veličine uzorka:

$$n' = \left[\frac{z \cdot \sigma}{\text{greska}} \right]^2$$

Korekcija za konačne osnovne skupove gdje je frakcija manja od 0.05

$$n = \frac{n'}{1 + \frac{n'}{N}}$$

10. Procjena proporcije (relativne frekvencije) na osnovu uzorka.

$$\Pr \left\{ \hat{p} - z \cdot Se(p) < P < \hat{p} + z \cdot Se(p) \right\} = 1 - \alpha$$

Procjena proporcije na osnovu uzorka nepristrana je.

Pri tomu se standardna grješka procjene proporcije dobiva ovako:

$$Se(p) = \sqrt{\frac{\hat{p} \cdot \hat{q}}{n}} \quad \text{ako je } n > 30 \text{ jedinica}$$

$$Se(p) = \sqrt{\frac{\hat{p} \cdot \hat{q}}{n-1}} \quad \text{ako je } n < 30 \text{ jedinica}$$

$$p = m / n; \quad q = (1-p)$$

Korekcija za konačne skupove je ista kao i kod procjene aritmetičke sredine osnovnoga skupa.

11. Procjena varijance na osnovu uzorka.

Procjena varijance na osnovu uzorka je pristrana. Sampling distribucija varijanci ima oblik Hi-kvadrat distribucije. Nepristrana ocjena varijance osnovnoga skupa može se dobiti ovako:

$$s^2 = \hat{\sigma}^2 \cdot \frac{n}{n-1} \quad s^2 \text{ predstavlja nepristranu procjenu varijance osnovnoga skupa}$$

Intervalna procjena varijance osnovnoga skupa:

$$\Pr \left\{ \frac{n \cdot s^2}{\chi^2_{\alpha/2}} < \sigma^2 < \frac{n \cdot s^2}{\chi^2_{1-\alpha/2}} \right\} = 1 - \alpha$$

U koliko veličina uzorka prelazi 30 jedinica Hi-kvadrat distribucija distribucija može se aproksimirati pomoću normalne distribucije. Tada se vrijednosti Hi-kvadrata mogu dobiti pomoću slijedeće formule:

$$\chi^2_{\alpha/2} = \frac{1}{2} \left(z_{\frac{1-\alpha}{2}} + \sqrt{2 \cdot v - 1} \right)^2 \quad \chi^2_{1-\alpha/2} = \frac{1}{2} \left(-z_{\frac{1-\alpha}{2}} + \sqrt{2 \cdot v - 1} \right)^2$$