

MODELI RAČUNARSTVA - JEZIČNI PROCESORI 1

Siniša Srbljić, Sveučilište u Zagrebu

1. UVOD

2. REGULARNI JEZICI

3. KONTEKSTNO NEOVISNI JEZICI

4. REKURZIVNO PREBROJIVI JEZICI

5. KONTEKSTNO OVISNI JEZICI

6. RAZREDBA (TAKSONOMIJA) JEZIKA, AUTOMATA I GRAMATIKA

3. KONTEKSTNO NEOVISNI JEZICI

3.1. KONTEKSTNO NEOVISNA GRAMATIKA

3.2. POTISNI AUTOMAT

3.3. SVOJSTVA KONTEKSTNO NEOVISNIH JEZIKA

3. KONTEKSTNO NEOVISNI JEZICI

- KONTEKSTNO NEOVISNI JEZIK I GRAMATIKA
 - jezik je kontekstno neovisan ako postoji kontekstno neovisna gramatika koja ga generira
 - time je definirana istovjetnost kontekstno neovisnih jezika i gramatika
 - klasa kontekstno neovisnih jezika sadrži kao podskup regularne jezike
 - jezik $N = \{wcw^R\}$ nije regularan, ali ga je moguće generirati kontekstno neovisnom gramatikom

3.1. Kontekstno neovisna gramatika (Context Free Grammar, CFG)

3.1.1. Nejednoznačnost gramatike, jezika i niza

3.1.2. Pojednostavljenje gramatike


3.1.3. Parsiranje niza

3.1.1. Nejednoznačnost gramatike, jezika i niza

- INTERPRETACIJA NIZA
 - zasniva se na generativnom stablu
 - za neke nizove moguće je izgraditi više stabala
 - npr. $G = (\{E\}, \{a, \otimes\}, \{E \rightarrow E \otimes E | a\}, E)$
 - za niz $a \otimes a \otimes a$ moguće je izgraditi dva generativna stabla
 - interpretacija niza je nejednoznačna jer ne možemo odrediti generativno stablo
 - različito stablo dobijemo
 - promjenom redoslijeda produkcija
 - promjenom redoslijeda nezavršnih znakova


Nejednoznačnost gramatike, jezika i niza

• NEJEDNOZNAČNOST NIZA



$$(1) \underline{E} \Rightarrow \underline{E} \otimes E \Rightarrow \underline{E} \otimes E \otimes E \Rightarrow a \otimes \underline{E} \otimes E \\ \Rightarrow a \otimes a \otimes \underline{E} \Rightarrow a \otimes a \otimes a$$

$$(3) \underline{E} \Rightarrow E \otimes \underline{E} \Rightarrow \underline{E} \otimes a \Rightarrow E \otimes \underline{E} \otimes a \\ \Rightarrow \underline{E} \otimes a \otimes a \Rightarrow a \otimes a \otimes a$$



$$(2) \underline{E} \Rightarrow \underline{E} \otimes E \Rightarrow a \otimes \underline{E} \Rightarrow a \otimes \underline{E} \otimes E \\ \Rightarrow a \otimes a \otimes \underline{E} \Rightarrow a \otimes a \otimes a$$

$$(4) \underline{E} \Rightarrow E \otimes \underline{E} \Rightarrow E \otimes E \otimes \underline{E} \Rightarrow E \otimes \underline{E} \otimes a \\ \Rightarrow \underline{E} \otimes a \otimes a \Rightarrow a \otimes a \otimes a$$

Nejednoznačnost gramatike, jezika i niza

- NEJEDNOZNAČNOST NIZA

- generativno stablo određuje **grupiranje**:
$$(a \otimes a) \otimes a \qquad a \otimes (a \otimes a)$$
- u slučaju aritmetičkog izraza grupiranje određuje redoslijed operacija
- za neke operacije to je bitno, npr. oduzimanje
- nastojimo konstruirati gramatiku koja za zadani niz gradi samo jedno stablo
- utvrdili smo:
 - za bilo koji niz CFG moguće je izgraditi jedno ili više stabala
 - bilo koje stablo moguće je izgraditi jednim ili više postupaka


Nejednoznačnost gramatike, jezika i niza

- ZAMJENA KRAJNJIH NEZAVRŠNIH ZNAKOVA
 - redoslijed zamjene nezavršnih znakova je značajan
 - uvedimo postupak zamjene krajnjeg desnog ili krajnjeg lijevog nezavršnog znaka
 - kod zamjene **krajnjeg lijevog** produkcije primjenjujemo samo na krajnji lijevi nezavršni znak u izrazu, (1) i (2)
 - kod zamjene **krajnjeg desnog** produkcije primjenjujemo samo na krajnji desni nezavršni znak u izrazu, (3) i (4)

Nejednoznačnost gramatike, jezika i niza

- OBILAZAK STABLA

- postupak obilaska stabla određuje redoslijed grana i čvorova
- koristimo **desni obilazak** ili **lijevi obilazak**
- obilazak započinje korijenom i
 - kod desnog obilazi rekurzivno sve desne čvorove i grane
 - kod lijevog obilazi rekurzivno sve lijeve čvorove i grane
- “desno” i “lijevo” se određuju pogledom sa korijena:



Nejednoznačnost gramatike, jezika i niza

- OBILAZAK STABLA

- postupak obilaska za neko stablo jednoznačno određuje
 - redoslijed primjene produkcija i
 - redoslijed zamjene znakova
- **desni** obilazak definira zamjenu krajnje **lijevog** znaka
- **lijevi** obilazak definira zamjenu krajnje **desnog** znaka
- za stablo $(a \otimes a) \otimes a$ to su postupci (1) i (3)
- to su ujedno jedini postupci koji generiraju to stablo
- bilo koje stablo moguće je izgraditi primjenom jednog i samo jednog postupka zamjene krajnje lijevog ili desnog znaka

Nejednoznačnost gramatike, jezika i niza

- **DEFINIRANJE NEJEDNOZNAČNOSTI**

- **Nejednoznačnost CFG G definiramo**

- ako je za niz $w \in L(G)$ moguće izgraditi više različitih generativnih stabala, gramatika je nejednoznačna
 - ako je niz $w \in L(G)$ moguće generirati primjenom više postupaka zamjene krajnjeg desnog ili krajnjeg lijevog znaka, onda je gramatika nejednoznačna

- gramatika

$G = (\{E\}, \{a, \otimes\}, \{E \rightarrow E \otimes E | a\}, E)$
je nejednoznačna

Nejednoznačnost gramatike, jezika i niza

- **DEFINIRANJE NEJEDNOZNAČNOSTI**

- **Nejednoznačnost niza** definiramo

- ako je za niz w moguće izgraditi više različitih generativnih stabala, on je nejednoznačan

- **Nejednoznačnost jezika** definiramo

- ako jezik L nije moguće generirati niti jednom jednoznačnom gramatikom, onda je jezik L nejednoznačan

- primjer nejednoznačnog jezika je:

$$L_n = L_1 \cup L_2 = \{a^n b^n c^m d^m \mid n \geq 1, m \geq 1\} \cup \{a^n b^m c^m d^n \mid n \geq 1, m \geq 1\}$$

Nejednoznačnost gramatike, jezika i niza

- RAZRJEŠAVANJE NEJEDNOZNAČNOSTI
 - Nejednoznačnost razrješujemo:
 - umjesto gramatike G izgradi se nova jednoznačna gramatika G'
 - Promjenom gramatike
 - Promjenom jezika
 - umjesto gramatike L izgradi se novi jezik L' koji je moguće generirati jednoznačnom gramatikom

Nejednoznačnost gramatike, jezika i niza

- PROMJENA GRAMATIKE

- jezik L kojeg generira $G = (\{E\}, \{a, \otimes\}, \{E \rightarrow E \otimes E | a\}, E)$ moguće je generirati više različitih jednoznačnih gramatika:
- Za lijevo asocijativni \otimes uvodimo gramatiku:
 $G_1 = (\{E, T\}, \{a, \otimes\}, \{E \rightarrow E \otimes T | T, T \rightarrow a\}, E)$
- Za desno asocijativni \otimes uvodimo gramatiku:
 $G_2 = (\{E, T\}, \{a, \otimes\}, \{E \rightarrow T \otimes E | T, T \rightarrow a\}, E)$
- izbor jednoznačne gramatike određuje način gradnje generativnog stabla


Nejednoznačnost gramatike, jezika i niza

- PROMJENA GRAMATIKE

- lijevo asocijativna gramatika

$$G_1 = (\{E, T\}, \{a, \otimes\}, \{E \rightarrow E \otimes T \mid T, T \rightarrow a\}, E)$$

daje niz:



$$(5) \quad \underline{E} \Rightarrow \underline{E} \otimes T \Rightarrow \underline{E} \otimes T \otimes T \Rightarrow \underline{T} \otimes T \otimes T \\ \Rightarrow a \otimes T \otimes T \Rightarrow a \otimes a \otimes T \Rightarrow a \otimes a \otimes a$$

$$(6) \quad \underline{E} \Rightarrow E \otimes \underline{T} \Rightarrow \underline{E} \otimes a \Rightarrow E \otimes \underline{T} \otimes a \\ \Rightarrow E \otimes a \otimes a \Rightarrow T \otimes a \otimes a \Rightarrow a \otimes a \otimes a$$


Nejednoznačnost gramatike, jezika i niza

- PROMJENA GRAMATIKE

- desno asocijativna gramatika

$$G_2 = (\{E, T\}, \{a, \otimes\}, \{E \rightarrow T \otimes E \mid T, T \rightarrow a\}, E)$$

daje niz:



$$\begin{aligned} (7) \quad \underline{E} &\Rightarrow \underline{T} \otimes E \Rightarrow a \otimes \underline{E} \Rightarrow a \otimes \underline{T} \otimes E \\ &\Rightarrow a \otimes a \otimes \underline{E} \Rightarrow a \otimes a \otimes \underline{T} \Rightarrow a \otimes a \otimes a \end{aligned}$$

$$\begin{aligned} (8) \quad \underline{E} &\Rightarrow T \otimes \underline{E} \Rightarrow T \otimes T \otimes \underline{E} \Rightarrow T \otimes T \otimes \underline{T} \\ &\Rightarrow T \otimes \underline{T} \otimes a \Rightarrow \underline{T} \otimes a \otimes a \Rightarrow a \otimes a \otimes a \end{aligned}$$

Nejednoznačnost gramatike, jezika i niza

- PRIMJER IF-THEN-ELSE

- gramatika

$G = (\{S, B\}, \{\text{if, then, else, true, false}\},$

$\{S \rightarrow \text{if } B \text{ then } S \text{ else } S \mid \text{if } B \text{ then } S, B \rightarrow \text{true} \mid \text{false}\}, S)$

generira složene naredbe programskog jezika

- nezavršni znak S generira naredbu, a B logički izraz
- gramatika nije jednoznačna, što je vidljivo na primjeru
if B then if B then S else S
- moguće je izgraditi dva generativna stabla
- algol je bio nejednoznačan


Nejednoznačnost gramatike, jezika i niza

- PRIMJER IF-THEN-ELSE

- if true then

- if false then print X

- else print Y




$\underline{S} \Rightarrow \text{if } B \text{ then } \underline{S} \Rightarrow$

$\Rightarrow \text{if } B \text{ then if } B \text{ then } S \text{ else } S$

Nejednoznačnost gramatike, jezika i niza

- PRIMJER IF-THEN-ELSE

- **if true then**
 if false then print X
else print Y



$\underline{S} \Rightarrow \text{if } B \text{ then } \underline{S} \text{ else } S \Rightarrow$
 $\Rightarrow \text{if } B \text{ then if } B \text{ then } S \text{ else } S$

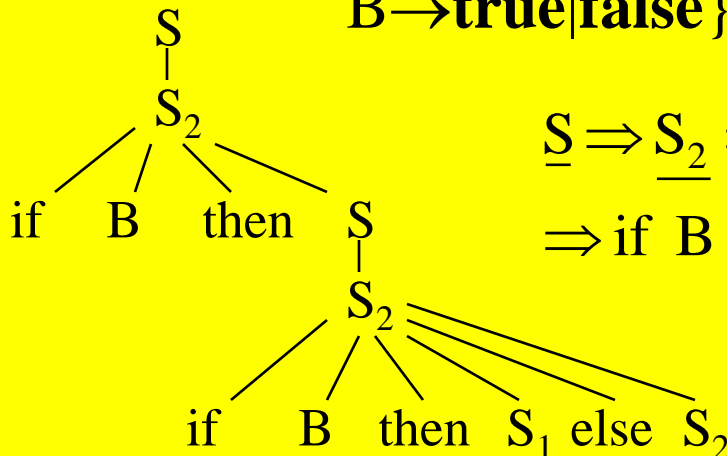
Nejednoznačnost gramatike, jezika i niza

- PRIMJER IF-THEN-ELSE

- problem rješavamo gramatikom

$G = (\{S, S_1, S_2, B\}, \{\text{if, then, else, true, false}\}, P, S)$

$P = \{ \begin{array}{l} S \rightarrow S_1 | S_2, \\ S_1 \rightarrow \text{if } B \text{ then } S_1 \text{ else } S_2, \\ S_2 \rightarrow \text{if } B \text{ then } S | \text{if } B \text{ then } S_1 \text{ else } S_2, \\ B \rightarrow \text{true} | \text{false} \end{array} \}$



$\underline{S} \Rightarrow \underline{S_2} \Rightarrow \text{if } B \text{ then } \underline{S} \Rightarrow \text{if } B \text{ then } \underline{S_2} \Rightarrow$
 $\Rightarrow \text{if } B \text{ then if } B \text{ then } S_1 \text{ else } S_2$


Nejednoznačnost gramatike, jezika i niza

- PROMJENA JEZIKA

- promjenu jezika primjenjujemo
 - kada je jezik inherentno nejednoznačan
 - kada je jednoznačna gramatika previše složena
 - kada se žele sačuvati sve interpretacije nizova
- primjer promjene jezika je uvođenje zagrada, zagrade su završni znakovi gramatike i dio su niza
- npr. pogledajmo gramatiku
$$G_3 = (\{E\}, \{a, \otimes, (,)\}, \{E \rightarrow (E) \otimes (E) | a\}, E)$$
- sada su nizovi $(a) \otimes ((a) \otimes (a))$ i $((a) \otimes (a)) \otimes (a)$ jednoznačni

Nejednoznačnost gramatike, jezika i niza


- PROMJENA JEZIKA



$$\begin{aligned} \underline{E} &\Rightarrow (\underline{E}) \otimes (E) \Rightarrow ((E) \otimes (E)) \otimes (E) \\ &\stackrel{*}{\Rightarrow} ((a) \otimes (a)) \otimes (a) \end{aligned}$$

Nejednoznačnost gramatike, jezika i niza

- PROMJENA JEZIKA



$$\begin{aligned} \underline{E} &\Rightarrow (\underline{E}) \otimes (E) \Rightarrow (a) \otimes (\underline{E}) \\ &\Rightarrow (a) \otimes ((E) \otimes (E)) \\ &\stackrel{*}{\Rightarrow} (a) \otimes ((a) \otimes (a)) \end{aligned}$$

Nejednoznačnost gramatike, jezika i niza

- RAZLIKA PROMJENA GRAMATIKE I JEZIKA
 - promjenom gramatike
 - ne mijenja se jezik
 - odbacuje se višestruko značenje niza
 - promjenom jezika
 - čuva se višestruko značenje niza
 - definira se zaseban niz za svako značenje
 - primjer:
 - lijevo asocijativna gramatika G_1
 - desno asocijativna gramatika G_2
 - gramatika promijenjenog jezika sa zagradama G_3
 - u programskim jezicima koristimo $\{ \}$ za složene naredbe

3.1.2. Pojednostavljenje gramatike

- POSTUPCI POJEDNOSTAVLJENJA
 - odbacuju beskorisne znakove i produkcije
 - generiramo gramatiku sa tri svojstva:
 - (i) bilo koji znak koristi se u makar jednom nizu
 - (ii) ne koriste se jedinične produkcije $A \rightarrow B$
 - (iii) ne koriste se ε -produkcije
 - koristimo algoritme
 - odbacivanja beskorisnih znakova
 - odbacivanja jediničnih produkcija i ε -produkcija
 - postizanja normalnih oblika Chomskog i Greibacha

Pojednostavljenje gramatike

- POSTUPCI POJEDNOSTAVLJENJA

(i) bilo koji znak gramatike G koristi se za generiranje makar jednog niza jezika L

- ako se znak X gramatike $G = (V, T, P, S)$ koristi u postupku generiranja:

$$S \xRightarrow{*} \alpha X \beta \xRightarrow{*} w \quad ; \quad \alpha, \beta \in (V \cup T)^*, \quad w \in T^*$$

onda je X koristan, u suprotnom je **beskoristan**

- dva su vida beskorisnosti:
 - znak je mrtav
 - znak je nedohvatljiv

Pojednostavljenje gramatike

- POSTUPCI POJEDNOSTAVLJENJA

- ako iz znaka X nije moguće generirati niz završnih znakova, tj. ako ne postoji postupak:

$$X \not\Rightarrow^* w_X \quad ; \quad w_X \in T^*$$

onda je znak X **mrtav**, u suprotnom je živ

- ako znak X nije ni u jednom nizu koji se generira iz S , tj. ako ne postoji postupak:

$$S \not\Rightarrow^* \alpha X \beta$$

onda je znak X **nedohvatljiv**

Pojednostavljenje gramatike

- POSTUPCI POJEDNOSTAVLJENJA

- neka je X dohvatljiv i živ tj. neka vrijedi:

$$S \xRightarrow{*} \alpha X \beta \quad X \xRightarrow{*} w_X \quad ; \quad w_X \in T^*$$

znak X nije nužno koristan

- moguće je da jedan od podnizova α ili β sadrži mrtvi znak
- ako u bilo kojem postupku $S \xRightarrow{*} \alpha X \beta$ barem jedan podniz sadrži mrtvi znak, X je beskoristan

Pojednostavljenje gramatike

- POSTUPCI POJEDNOSTAVLJENJA

(ii) gramatika G nema jediničnih produkcija tipa $A \rightarrow B$

- $A \rightarrow B$ je jedinična produkcija
- sve ostale produkcije uključujući $A \rightarrow a$ i $A \rightarrow \varepsilon$ nazivaju se nejedinične produkcije

Pojednostavljenje gramatike

- POSTUPCI POJEDNOSTAVLJENJA

(iii) ako prazni niz ε nije element jezika L , moguće je izbjeći korištenje produkcija tipa $A \rightarrow \varepsilon$

- produkcija $A \rightarrow \varepsilon$ naziva se ε -produkcija
- gramatiku G preuredimo tako da sve produkcije budu oblika $A \rightarrow BC$ i $A \rightarrow a$,
te su u normalnom obliku Chomskog
- gramatiku G preuredimo tako da sve produkcije budu oblika $A \rightarrow a\alpha$, α može biti prazan
te su u normalnom obliku Greibacha

Pojednostavljenje gramatike

- ODBACIVANJE MRTVIH ZNAKOVA

- neka CFG $G = (V, T, P, S)$
generira neprazan jezik $L(G) \neq \emptyset$
- moguće je izgraditi istovjetnu CFG $G' = (V', T', P', S)$,
 $L(G) = L(G')$, koja **nema mrtvih znakova** tako da je

$$A \xRightarrow{*} w ; w \in T^*$$

- npr. $G = (\{S, A, B\}, \{a, b, c, d, e, f\}, P, S)$
 $P = \{S \rightarrow aSa, S \rightarrow bAd, S \rightarrow c,$
 $A \rightarrow cBd, A \rightarrow aAd, B \rightarrow dAf\}$
- nezavršni znakovi A i B su mrtvi znakovi

Pojednostavljenje gramatike

- ALGORITAM TRAŽENJA ŽIVIH ZNAKOVA
 - ako su živi svi znakovi desne strane produkcije

$$A \rightarrow X_1 X_2 \cdots X_n$$

živ je i nezavršni znak s lijeve strane produkcije

- budući da s desna nema mrtvih znakova, vrijedi:

$$X_i \rightarrow w_i; w_i \in T^*$$

- stoga vrijedi:

$$A \rightarrow w_1 w_2 \cdots w_n = w$$

Pojednostavljenje gramatike

- ALGORITAM TRAŽENJA ŽIVIH ZNAKOVA
 - algoritam se provodi u tri koraka:
 1. U listu živih znakova stave se lijeve strane produkcija koje na desnoj nemaju nezavršnih znakova
 2. Ako su s desne strane produkcije isključivo živi znakovi, onda se u listu doda znak s lijeve strane
 3. Ako se lista živih ne može proširiti, svi znakovi koji nisu na listi su mrtvi znakovi

Pojednostavljenje gramatike

- ALGORITAM TRAŽENJA ŽIVIH ZNAKOVA

- primjer: $G = (\{S, A, B, C\}, \{a,b,c,d\}, P, S)$

- 1) $S \rightarrow aABS$

- 4) $A \rightarrow cSA$

- 7) $B \rightarrow cSB$

- 2) $S \rightarrow bCACd$

- 5) $A \rightarrow cCC$

- 8) $C \rightarrow cS$

- 3) $A \rightarrow bAB$

- 6) $B \rightarrow bAB$

- 9) $C \rightarrow c$

- u listu stavljamo žive znakove:

- C zbog 9), A zbog 5) i S zbog 2)

- B je mrtav, odbacujemo produkcije i dobijemo:

- $G = (\{S, A, C\}, \{a,b,c,d\}, P, S)$

- 2) $S \rightarrow bCACd$

- 4) $A \rightarrow cSA$

- 8) $C \rightarrow cS$

- 5) $A \rightarrow cCC$

- 9) $C \rightarrow c$

Pojednostavljenje gramatike

- ODBACIVANJE NEDOHVATLJIVIH ZNAKOVA

- neka CFG $G = (V, T, P, S)$ generira jezik $L(G) \neq \emptyset$
- moguće je izgraditi istovjetnu CFG $G' = (V', T', P', S)$, $L(G) = L(G')$, koja **nema nedohvatljivih znakova**

$$X \in V' \cup T': S \xRightarrow{*} \alpha X \beta ; \alpha, \beta \in (V' \cup T')^*$$

- npr. $G = (\{S, A\}, \{a, b, c\}, P, S)$
 $P = \{S \rightarrow aSb, S \rightarrow c, A \rightarrow bS, A \rightarrow a\}$
- produkcije sa S na lijevoj strani nemaju A na desnoj, pa je A nedohvatljiv, ostaju samo produkcije iz S

Pojednostavljenje gramatike

- TRAŽENJE DOHVATLJIVIH ZNAKOVA

- ako je dohvatljiv nezavršni znak s lijeve strane produkcije

$$A \rightarrow \alpha_1 | \alpha_2 | \alpha_3 \cdots | \alpha_n$$

onda su dohvatljivi svi završni i nezavršni znakovi s desne strane produkcije

- neka je S početni nezavršni znak, i neka je A dohvatljiv vrijedi:

$$S \xRightarrow{*} \beta A \gamma \Rightarrow \beta \alpha_i \gamma; i = 1 \cdots n$$

- pa su svi znakovi α_i dohvatljivi

Pojednostavljenje gramatike

- TRAŽENJE DOHVATLJIVIH ZNAKOVA
 - algoritam se provodi u tri koraka:
 1. U listu dohvatljivih znakova stavi se početni nezavršni znak gramatike
 2. Ako je znak s lijeve strane produkcije dohvatljiv, u listu se dodaju svi znakovi s desne strane produkcije
 3. Ako se lista dohvatljivih ne može proširiti, svi znakovi koji nisu na listi su nedohvatljivi znakovi

Pojednostavljenje gramatike

- TRAŽENJE DOHVATLJIVIH ZNAKOVA

- primjer: $G = (\{S, A, B, C, D, E\}, \{a,b,c,d,e,f,g\}, P, S)$

- 1) $S \rightarrow aAB$

- 5) $B \rightarrow bE$

- 9) $C \rightarrow a$

- 2) $S \rightarrow E$

- 6) $B \rightarrow f$

- 10) $D \rightarrow eA$

- 3) $A \rightarrow dDA$

- 7) $C \rightarrow cAB$

- 11) $E \rightarrow fA$

- 4) $A \rightarrow e$

- 8) $C \rightarrow dSD$

- 12) $E \rightarrow g$

- u listu stavljamo dohvatljive znakove:

- S ; A, B i a zbog 1), E zbog 2) d i D zbog 3), e zbog 4) b zbog 5), f zbog 6), e zbog 10) i g zbog 12)

- C i c su nedohvatljivi, odbacujemo produkcije pa je:

- $G = (\{S, A, B, D, E\}, \{a,b,d,e,f\}, P, S)$

- odbacimo produkcije 7, 8 i 9

Pojednostavljenje gramatike

- ODBACIVANJE BESKORISNIH ZNAKOVA

- primjenom algoritma
 - odbacivanja mrtvih znakova
 - pa odbacivanja nedohvatljivih znakova
- iz gramatike se izbace svi beskorisni znakovi
- nužno je ići tim redoslijedom (odbaciti prvo mrtve)
- primjer: $G = (\{S, A, B\}, \{a\}, P, S)$
 $S \rightarrow AB|a$ $A \rightarrow a$
- B je mrtav, ostaje: $S \rightarrow a$ $A \rightarrow a$
- A je nedohvatljiv, ostaje $S \rightarrow a$
- obrnuto: A bi bio dohvatljiv, a samo B bi bio mrtav

Pojednostavljenje gramatike

- ODBACIVANJE BESKORISNIH ZNAKOVA

- neka CFG $G = (V, T, P, S)$ generira jezik $L(G) \neq \emptyset$
 - moguće je izgraditi istovjetnu CFG $G' = (V', T', P', S)$, $L(G) = L(G')$, koja **nema beskorisnih znakova**
 - neka je G_1 nastala odbacivanjem mrtvih znakova iz G
 - neka je G_2 nastala odbacivanjem nedohvatljivih iz G_1
 - G_2 nema nedohvatljivih znakova i vrijedi $S \xRightarrow[G_2]{*} \alpha X \beta$
 - kako G_1 i G_2 imaju iste znakove, a G_1 nema mrtvih, onda ni G_2 nema mrtvih znakova pa su svi znakovi u nizu $\alpha X \beta$ živi
- $$S \xRightarrow[G_2]{*} \alpha X \beta \xRightarrow[G_2]{*} w, \quad w \in T^*$$

Pojednostavljenje gramatike

- ODBACIVANJE BESKORISNIH ZNAKOVA

- primjer: $G = (\{S, A, B, C\}, \{a,b,c,d\}, P, S)$

- 1) $S \rightarrow ac$

- 3) $A \rightarrow cBC$

- 5) $C \rightarrow bC$

- 2) $S \rightarrow bA$

- 4) $B \rightarrow aSA$

- 6) $C \rightarrow d$

- u listu stavljamo žive znakove: C zbog 6) i S zbog 1)

- A i B su mrtvi, dobijemo: $G_1 = (\{S, C\}, \{a,b,c,d\}, P_1, S)$

- 1) $S \rightarrow ac$

- 5) $C \rightarrow bC$

- 6) $C \rightarrow d$

- u listu stavljamo dohvatljive znakove: S

- C, b i d su nedohvatljivi, dobijemo:

- $G_2 = (\{S\}, \{a,c\}, P_2, S)$

- 1) $S \rightarrow ac$

Pojednostavljenje gramatike

- ODBACIVANJE ε -PRODUKCIJA

- neka CFG $G = (V, T, P, S)$ generira jezik $L(G) \setminus \{\varepsilon\}$
- moguće je izgraditi istovjetnu CFG $G' = (V', T', P', S)$ $L(G) = L(G')$, koja **nema ε -produkcija** $A \rightarrow \varepsilon$
- primjer: $G = (\{S, A\}, \{a, b, c\}, P, S)$

1) $S \rightarrow aASA$ 2) $S \rightarrow b$ 3) $A \rightarrow cS$ 4) $A \rightarrow \varepsilon$

- umjesto nezavršnog znaka A definiramo dva: A_{DA} i A_{NE}
- A_{DA} koristimo u produkciji 4, A_{NE} u produkciji 3, zamijenimo:
1a) $S \rightarrow aA_{NE}SA_{NE}$ 1b) $S \rightarrow aA_{NE}SA_{DA}$ 1c) $S \rightarrow aA_{DA}SA_{NE}$
1d) $S \rightarrow aA_{DA}SA_{DA}$ 2) $S \rightarrow b$ 3) $A_{NE} \rightarrow cS$ 4) $A_{DA} \rightarrow \varepsilon$
- zamijenimo A_{DA} s ε , odbacimo 4), A_{NE} zamijenimo s A :
1a) $S \rightarrow aASA$ 1b) $S \rightarrow aAS$ 1c) $S \rightarrow aSA$ 1d) $S \rightarrow aS$
2) $S \rightarrow b$ 3) $A \rightarrow cS$

Pojednostavljenje gramatike

- ODBACIVANJE ε -PRODUKCIJA

- algoritam se izvodi u dva osnovna koraka:

- 1) pronađu se svi nezavršni znakovi
koji generiraju prazni niz:

$$A \overset{*}{\Rightarrow} \varepsilon$$

- u listu praznih znakova stave se sve lijeve strane ε -produkcija
 - ako su svi znakovi desne strane u listi, lista se nadopuni lijevom
 - algoritam se nastavlja sve dok se lista može širiti

Pojednostavljenje gramatike

- ODBACIVANJE ε -PRODUKCIJA

2) gradi se novi skup produkcija gramatike G'

- za produkciju iz G : $A \rightarrow X_1 X_2 \dots X_n$
dodaju se u G' produkcije $A \rightarrow \xi_1 \xi_2 \dots \xi_n$
- oznake ξ_i poprimaju vrijednosti:
 - X_i ako je X_i neprazan,
 - X_i ili ε ako je X_i prazan
- kada svi ξ_i poprimu vrijednost ε nastaje ε -produkcija koja se NE dodaje u listu produkcija G'
- ako produkcija na desnoj strani ima k praznih znakova,
 - potrebno je izgraditi 2^k novih produkcija
 - ako je s desne strane neprazni znak, svih 2^k produkcija ostaje
 - ako s desne strane nije neprazni znak, ostaje $2^k - 1$ produkcija

Pojednostavljenje gramatike

- ODBACIVANJE JEDINIČNIH PRODUKCIJA
 - neka CFG $G = (V, T, P, S)$ generira jezik $L(G) \setminus \{\varepsilon\}$
 - moguće je izgraditi istovjetnu CFG $G' = (V', T', P', S)$, $L(G) = L(G')$, koja **nema jediničnih produkcija** $A \rightarrow B$
 - algoritam se provodi u dva koraka:
 - 1) u P' stave se sve produkcije iz P koje nisu jedinične
 - 2) za sve postupke generiranja B iz A

$$A \xRightarrow{*} B$$

na osnovu $B \rightarrow \alpha$ stvore se nove produkcije $A \rightarrow \alpha$

Pojednostavljenje gramatike

- CHOMSKYJEV NORMALNI OBLIK
(Chomsky Normal Form, CNF)
 - neka CFG $G = (V, T, P, S)$ generira jezik $L(G) \setminus \{\varepsilon\}$
 - moguće je izgraditi istovjetnu CFG $G' = (V', T', P', S)$, $L(G) = L(G')$, koja **ima sve produkcije** oblika:
$$A \rightarrow BC \quad \text{ili} \quad A \rightarrow a$$
 - pretpostavi se da G nema beskorisnih znakova, ε -produkcija niti jediničnih produkcija
 - algoritam pretvorbe u CNF se provodi u tri koraka:

Pojednostavljenje gramatike

- CHOMSKYJEV NORMALNI OBLIK

1) u skup P' stave se sve produkcije koje su u CNF, tj.

$$A \rightarrow BC \quad \text{ili} \quad A \rightarrow a$$

a u skup V' upišu se svi nezavršni znakovi

2) neka je produkcija gramatike G oblika:

$$A \rightarrow X_1 X_2 \dots X_n ; \quad A \in V, X_i \in V \cup T$$

ako je X_i završni znak $a \in T$,

- skup nezavršnih znakova proširi se sa $C_a \in V'$
- skup produkcija proširi se sa $C_a \rightarrow a$ koja je u CNF
- svi završni znakovi a zamijene se sa C_a
- postupak se nastavlja dok se ne zamijene svi završni znakovi
- postupak se nastavlja za sve produkcije

Pojednostavljenje gramatike

- CHOMSKYJEV NORMALNI OBLIK

3) nakon koraka 2

- sve su produkcije u P' oblika $A \rightarrow a$ ili $A \rightarrow B_1 B_2 B_3 \dots B_m$,
- a one oblika $A \rightarrow BC$ ili $A \rightarrow a$ su u CNF

produkcije koje s desna imaju 3 ili više znakova

- mijenjaju se u ovim produkcijama
- definiraju se novi znakovi $D_1 D_2 D_3 \dots D_{m-2}$
- pa se $A \rightarrow B_1 B_2 B_3 \dots B_m$ zamijeni skupom produkcija:
 $\{A \rightarrow B_1 D_1, D_1 \rightarrow B_2 D_2, D_2 \rightarrow B_3 D_3, \dots, D_{m-2} \rightarrow B_{m-1} B_m\}$

Pojednostavljenje gramatike

- CHOMSKYJEV NORMALNI OBLIK

- primjer: $G = (\{S, A, B\}, \{a, b\}, P, S)$

1) $S \rightarrow bA$

3) $A \rightarrow bAA$

6) $B \rightarrow aBB$

2) $S \rightarrow aB$

4) $A \rightarrow aS$

7) $B \rightarrow bS$

5) $A \rightarrow a$

8) $B \rightarrow b$

- produkcije 5 i 8 su u CNF

- definira se C_a i C_b , te dodaju produkcije $C_a \rightarrow a$ i $C_b \rightarrow b$:

1) $S \rightarrow C_bA$

3) $A \rightarrow C_bAA$

6) $B \rightarrow C_aBB$

9) $C_a \rightarrow a$

2) $S \rightarrow C_aB$

4) $A \rightarrow C_aS$

7) $B \rightarrow C_bS$

10) $C_b \rightarrow b$

5) $A \rightarrow a$

8) $B \rightarrow b$

- sada su 1, 2, 4, 5, 7, 8, 9 i 10 u CNF

Pojednostavljenje gramatike

- CHOMSKYJEV NORMALNI OBLIK

- primjer:

- treba razriješiti produkcije 3 i 6

- definira se D_1 i E_1 , te dodaju produkcije $D_1 \rightarrow AA$ i $E_1 \rightarrow BB$:

$$1) S \rightarrow C_b A \quad 3a) A \rightarrow C_b D_1 \quad 6a) B \rightarrow C_a E_1 \quad 9) C_a \rightarrow a$$

$$2) S \rightarrow C_a B \quad 3b) D_1 \rightarrow AA \quad 6a) E_1 \rightarrow BB \quad 10) C_b \rightarrow b$$

$$4) A \rightarrow C_a S \quad 7) B \rightarrow C_b S$$

$$5) A \rightarrow a \quad 8) B \rightarrow b$$

- sada su sve produkcije u CNF

Pojednostavljenje gramatike

- GREIBACHOV NORMALNI OBLIK

(Greibach Normal Form, GNF)

- neka CFG $G = (V, T, P, S)$ generira jezik $L(G) \setminus \{\varepsilon\}$
- moguće je izgraditi istovjetnu CFG $G' = (V', T', P', S)$, $L(G) = L(G')$, koja **ima sve produkcije** oblika:

$$A \rightarrow a\alpha; \quad \alpha \in V^*$$

- Koriste se tri postupka
 - algoritam pretvorbe gramatike u normalni oblik Chomskog
 - algoritam zamjene krajnjeg lijevog nezavršnog znaka
 - algoritam razrješenja lijeve rekurzije
- algoritam pretvorbe u CNF je opisan ranije

Pojednostavljenje gramatike

- ZAMJENA KRAJNJE LIJEVOG ZNAKA

- neka je u CFG $G = (V, T, P, S)$

- r produkcija koje imaju D_j s lijeve strane

$$D_j \rightarrow \alpha_1, D_j \rightarrow \alpha_2 \dots D_j \rightarrow \alpha_r$$

- produkcija koja ima D_j na krajnjem lijevom mjestu desne strane

$$D_i \rightarrow D_j \gamma$$

- prethodnih $r+1$ produkcija zamijeni se sa r produkcija:

$$D_i \rightarrow \alpha_1 \gamma, D_i \rightarrow \alpha_2 \gamma \dots D_i \rightarrow \alpha_r \gamma$$

- produkcije generiraju isti jezik

Pojednostavljenje gramatike

- RAZRJEŠENJE LIJEVE REKURZIJE
 - ako je isti nezavršni znak na lijevoj strani produkcije i krajnje lijevo na desnoj strani produkcije
 - produkcija je **lijevo rekurzivna**
 - gramatika se preuređuje:
 - neka je za D_i zadano r lijevo rekurzivnih produkcija
$$D_i \rightarrow D_i \alpha_1, D_i \rightarrow D_i \alpha_2 \dots D_i \rightarrow D_i \alpha_r$$
 - i s produkcija koje nisu lijevo rekurzivne
$$D_i \rightarrow \beta_1, D_i \rightarrow \beta_2 \dots D_i \rightarrow \beta_r$$
 - prethodnih $r+s$ produkcija zamijeni se sa:
$$D_i \rightarrow \beta_1, D_i \rightarrow \beta_1 C_i, C_i \rightarrow \alpha_k, C_i \rightarrow \alpha_k C_i$$
 - produkcije generiraju isti jezik

Pojednostavljenje gramatike

- **PRETVORBA PRODUKCIJA U GNF**
 - provodi se u četiri koraka:
1) korak:
 - produkcije gramatike G preurediti u CNF
produkcije su oblika $A \rightarrow BC$ ili $A \rightarrow a$
 - preimenovati m nezavršnih znakova u D_i , $i=1\dots m$
produkcije su oblika $D_i \rightarrow D_j D_k$ ili $D_i \rightarrow a$
 - produkcije $D_i \rightarrow a$ su u GNF

Pojednostavljenje gramatike

- PRETVORBA PRODUKCIJA U GNF

2) korak:

- produkcije oblika $D_i \rightarrow D_j D_k$ redom od $i=1$ do $i=m$ preurede se u oblik $D_i \rightarrow D_j \beta$, $j > i$
- za D_1 , produkcije su oblika $D_1 \rightarrow D_j D_k$, $j \geq 1$
 - za $j > 1$ produkcija je u prihvatljivom obliku
 - za $j = 1$ preuredimo razrješenjem lijeve rekurzije, pojavi se C_1
- za $D_i \rightarrow D_j D_k$, $i > 1$ moguće je slijedeće:
 - za $j < i$ preuredimo zamjenom lijevog nezavršnog znaka; zamjenjujemo iterativno sve dok ne postignemo $j \geq i$
 - za $j = i$ preuredimo razrješenjem lijeve rekurzije, pojavi se C_i
 - za $j > i$ produkcija je u prihvatljivom obliku

Pojednostavljenje gramatike

- PRETVORBA PRODUKCIJA U GNF

2) korak - nastavak:

– sve produkcije su oblika:

- $D_i \rightarrow D_j \beta$, $j > i$
- $D_i \rightarrow a \beta$, $a \in T$ produkcija je u GNF
- $C_i \rightarrow D_j \xi$, ξ niz znakova iz $\{D_i\} \cup \{C_i\}$
- $D_m \rightarrow a\alpha$, produkcija je u GNF

Pojednostavljenje gramatike

- PRETVORBA PRODUKCIJA U GNF

3) korak:

- produkcije oblika $D_i \rightarrow D_j \beta$ redom od $i=m-1$ do $i=1$ preurede se u oblik $D_i \rightarrow a\alpha\beta$
- za D_{m-1} , produkcije su oblika $D_{m-1} \rightarrow D_m \alpha \mid a\alpha$
 - $D_{m-1} \rightarrow a\alpha$ produkcija je u prihvatljivom obliku
 - $D_{m-1} \rightarrow D_m \alpha$ koristimo sigurno $D_m \rightarrow a\alpha$, dobijemo GNF
- za D_{m-k} , $k>1$, imamo produkcije $D_{m-k} \rightarrow D_j \alpha \mid a\alpha$, $j>m-k$
 - sigurno postoji produkcija $D_j \rightarrow a\alpha$:
 - preuredimo u oblik $D_{m-k} \rightarrow a\alpha\beta$, produkcija je u GNF
- sve produkcije su oblika:
 - $D_i \rightarrow a\beta$, $i \leq m$ $C_i \rightarrow D_j \xi$

Pojednostavljenje gramatike

- PRETVORBA PRODUKCIJA U GNF

- 4) korak:

- produkcije oblika $C_i \rightarrow D_j \xi$
preurede se u oblik $C_i \rightarrow a\beta$
 - u koraku 3 je postignuto $D_i \rightarrow a\beta$
 - primijenimo algoritam zamjene krajnje lijevog nezavršnog znaka
 - dobije se $C_i \rightarrow a \alpha \xi = C_i \rightarrow a\beta$, produkcija je u GNF
 - sve produkcije su oblika:
 - $D_i \rightarrow a\beta$, i $C_i \rightarrow a\beta$

Pojednostavljenje gramatike

- PRETVORBA PRODUKCIJA U GNF - PRIMJER

- primjer: $G = (\{S, A, B\}, \{a, b\}, P, S)$ zadana u CNF

- 1) $S \rightarrow AB$

- 2) $A \rightarrow BS$

- 4) $B \rightarrow SA$

- 3) $A \rightarrow b$

- 5) $B \rightarrow a$

- korak 1:

- gramatika je već u CNF

- zamijenimo S, A i B sa D_1 , D_2 i D_3

- 1) $D_1 \rightarrow D_2 D_3$

- 2) $D_2 \rightarrow D_3 D_1$

- 4) $D_3 \rightarrow D_1 D_2$

- 3) $D_2 \rightarrow b$

- 5) $D_3 \rightarrow a$

Pojednostavljenje gramatike

• PRETVORBA PRODUKCIJA U GNF - PRIMJER

– korak 2:

- produkcije 3 i 5 su već u GNF, $D_2 \rightarrow b$ i $D_3 \rightarrow a$
- produkcija 1 $D_1 \rightarrow D_2 D_3$ je OK, $j > i$
- produkcija 2 $D_2 \rightarrow D_3 D_1$ je OK, $j > i$
- produkciju 4 transformiramo zamjenom sa 1 pa 2 i 3:
$$D_3 \rightarrow D_1 D_2 \Rightarrow D_3 \rightarrow D_2 D_3 D_2 \Rightarrow D_3 \rightarrow D_3 D_1 D_3 D_2 \mid b D_3 D_2$$
- dobivena produkcija $D_3 \rightarrow b D_3 D_2$ je OK
- dobivenu produkciju $D_3 \rightarrow D_3 D_1 D_3 D_2$ transformiramo razrješenjem lijeve rekurzije:
$$D_3 \rightarrow D_3 D_1 D_3 D_2 \Rightarrow$$
$$D_3 \rightarrow b D_3 D_2 C_3 \mid a C_3 \quad \text{i} \quad C_3 \rightarrow D_1 D_3 D_2 \mid D_1 D_3 D_2 C_3$$

Pojednostavljenje gramatike

- PRETVORBA PRODUKCIJA U GNF - PRIMJER

- korak 3:

- počnemo sa D_2 , dobije se:

- $$D_2 \rightarrow D_3 D_1 \Rightarrow D_2 \rightarrow a D_1 \mid b D_3 D_2 D_1 \mid b D_3 D_2 C_3 D_1 \mid a C_3 D_1$$

od ranije imamo $D_2 \rightarrow b$

- nastavimo sa D_1 , dobije se:

- $$D_1 \rightarrow D_2 D_3 \Rightarrow D_1 \rightarrow b D_3 \mid a D_1 D_3 \mid b D_3 D_2 D_1 D_3 \mid$$
$$\mid b D_3 D_2 C_3 D_1 D_3 \mid a C_3 D_1 D_3$$

- od ranije imamo

- $$D_3 \rightarrow b D_3 D_2 C_3 \mid a C_3 \mid b D_3 D_2 \mid a$$
$$C_3 \rightarrow D_1 D_3 D_2 \mid D_1 D_3 D_2 C_3$$

Pojednostavljenje gramatike

- PRETVORBA PRODUKCIJA U GNF - PRIMJER

– korak 4:

- dovedimo $C_3 \rightarrow D_1 D_3 D_2 \mid D_1 D_3 D_2 C_3$ u GNF zamjenom:

$$\begin{aligned} C_3 \rightarrow D_1 D_3 D_2 &\Rightarrow C_3 \rightarrow b D_3 D_3 D_2 \mid a D_1 D_3 D_3 D_2 \mid \\ &\mid b D_3 D_2 D_1 D_3 D_3 D_2 \mid b D_3 D_2 C_3 D_1 D_3 D_3 D_2 \mid \\ &\mid a C_3 D_1 D_3 D_3 D_2 \end{aligned}$$

- i

$$\begin{aligned} C_3 \rightarrow D_1 D_3 D_2 C_3 &\Rightarrow C_3 \rightarrow b D_3 D_3 D_2 C_3 \mid a D_1 D_3 D_3 D_2 C_3 \mid \\ &\mid b D_3 D_2 D_1 D_3 D_3 D_2 C_3 \mid b D_3 D_2 C_3 D_1 D_3 D_3 D_2 C_3 \mid \\ &\mid a C_3 D_1 D_3 D_3 D_2 C_3 \end{aligned}$$

Pojednostavljenje gramatike

- PRETVORBA PRODUKCIJA U GNF - PRIMJER

- dobivena gramatika je u GNF:

- $D_1 \rightarrow b D_3 \mid a D_1 D_3 \mid b D_3 D_2 D_1 D_3 \mid$
 $\mid b D_3 D_2 C_3 D_1 D_3 \mid a C_3 D_1 D_3$
 - $D_2 \rightarrow a D_1 \mid b D_3 D_2 D_1 \mid b D_3 D_2 C_3 D_1 \mid a C_3 D_1 \mid b$
 - $D_3 \rightarrow b D_3 D_2 C_3 \mid a C_3 \mid b D_3 D_2 \mid a$
 - $C_3 \rightarrow b D_3 D_3 D_2 \mid a D_1 D_3 D_3 D_2 \mid b D_3 D_2 D_1 D_3 D_3 D_2 \mid$
 $\mid b D_3 D_2 C_3 D_1 D_3 D_3 D_2 \mid a C_3 D_1 D_3 D_3 D_2$
 - $C_3 \rightarrow b D_3 D_3 D_2 C_3 \mid a D_1 D_3 D_3 D_2 C_3 \mid b D_3 D_2 D_1 D_3 D_3 D_2 C_3$
 \mid
 $\mid b D_3 D_2 C_3 D_1 D_3 D_3 D_2 C_3 \mid a C_3 D_1 D_3 D_3 D_2 C_3$

3.1.3. Parsiranje niza

- PARSIRANJE JE POSTUPAK
 - prepoznavanja niza
 - izgradnje generativnog stabla
 - to je stablo parsiranja
 - razlikujemo metode:
 - od vrha prema dnu, započinje korijenom, odnosno od početnog nezavršnog znaka
 - od dna prema vrhu, započinje listovima, odnosno od završnih znakova

Parsiranje niza

- PARSIRANJE OD VRHA PREMA DNU
 - zadana je gramatika $G = (V, T, P, S)$
 - parsiranje započinje sa početnim nezavršnim znakom S
 - produkcije gramatike se primjenjuju sve dok se listovi stabla ne označe završnim znakovima traženog niza w
 - ovo parsiranje se široko primjenjuje zbog učinkovitosti
 - za višestruki izbor zamjene, treba ispitati sve kombinacije

Parsiranje niza

- PARSIRANJE OD VRHA PREMA DNU
PRIMJER

- gramatika G generira **begin-end** blokove
- generiraju se naredbe pridruživanja i **while** petlje
- zadano je: $V = \{C, S, S_1, S_2\}$; C je početni
 $T = \{\text{begin, end, while, do, }, :=, <>, \text{var}\}$
 $P = \{ C \rightarrow \text{begin } S_1 \text{ end}, S_1 \rightarrow SS_2, S_2 \rightarrow ;S_1 \mid \varepsilon$
 $S \rightarrow \text{var } := \text{var} \mid \text{while var } <> \text{var do } S \mid \text{begin } S_1 \text{ end} \}$
- **begin, end, while, do** su ključne riječi, **var** je varijabla,
:= je pridruživanje, **<>** je nejednakost, a **;** ulančavanje

Parsiranje niza


- TD PARSIRANJE PRIMJER

- parsirati niz: **begin var := var ;**
 while var <> var do
 var := var

 end

- započnimo korijenom i jedinom mogućom produkcijom:

- $C \rightarrow \text{begin } S_1 \text{ end}$




Parsiranje niza


- TD PARSIRANJE PRIMJER

- nadalje koristimo:

- $S_1 \rightarrow SS_2$ i
 $S \rightarrow \text{var} := \text{var}$



- $S_2 \rightarrow ; S_1$ i
• $S_1 \rightarrow SS_2$



Parsiranje niza

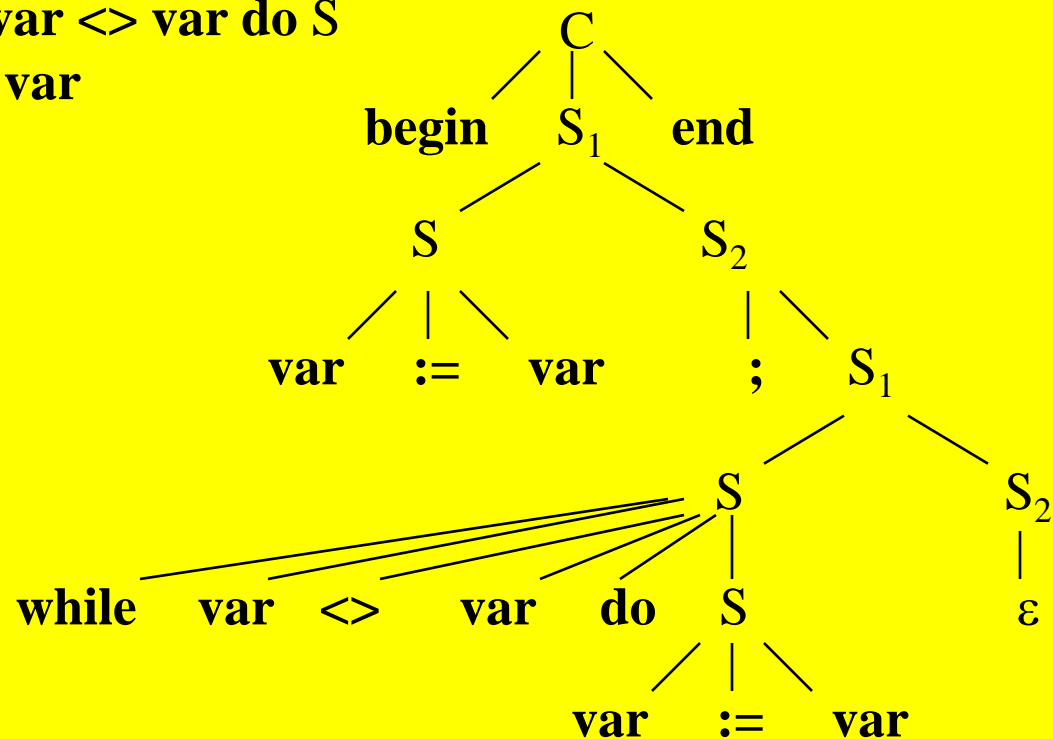
- TD PARSIRANJE PRIMJER

- nadalje koristimo:

- $S \rightarrow \text{while var} \langle \rangle \text{var do } S$

- $S \rightarrow \text{var} := \text{var}$

- $S_2 \rightarrow \varepsilon$



Parsiranje niza

- LL(1) GRAMATIKA i LL(1) PARSIRANJE
 - LL(1) gramatika i parsiranje od vrha prema dnu je:
 - L: ulazni niz čitamo s lijeva na desno (left to right scanning)
 - L: mijenjamo krajnje lijevi nezavršni znak (leftmost derivation)
 - (1): odluku donosimo na osnovu jednog pročitanoog znaka
 - produkcija se primijeni na osnovu
 - pročitanoog ulaznog znaka
 - krajnje lijevog nezavršnog znaka u generiranom nizu
 - primijeni se ona produkcija koja ima
 - na lijevoj strani nezavršni znak koji je krajnje lijevi u nizu
 - na desnoj strani na krajnje lijevom mjestu ima završni znak koji odgovara ulaznom nizu

Parsiranje niza

- LL(k) PARSIRANJE

- LL(k) gramatika i parsiranje od vrha prema dnu je:
 - L: ulazni niz čitamo s lijeva na desno (left to right scanning)
 - L: mijenjamo krajnje lijevi nezavršni znak (leftmost derivation)
 - (k): odluku donosimo na osnovu k pročitanih znakova ulaznog niza
- gramatika zadana Greibacnovom normalnom formom pogodna je za učinkovito ostvarenje LL(1) parsera
- u realizaciji LL(1) parsera primjenjujemo tehniku **rekurzivnog spusta**

Parsiranje niza

- TEHNIKA REKURZIVNOG SPUSTA
 - služi za programsko ostvarenje LL(k) parsera
 - koristi rekurzivno pozivanje potprograma
 - potprograme dodjeljujemo nezavršnim znakovima
 - potprogram ispituje da li podniz ulaznog niza odgovara desnoj strani produkcije nezavršnog znaka kojem pripada
 - za nezavršne znakove s desne strane poziva odgovarajuće potprograme
 - ako je isti znak s lijeve i desne strane produkcije, potprogram se poziva rekurzivno
 - moguća je i indirektna rekurzija, posredstvom drugih potprograma

Parsiranje niza

- TEHNIKA REKURZIVNOG SPUSTA PRIMJER
 - za gramatiku $G = (\{C, S, S_1, S_2\}, \{\text{begin, end, while, do, ;, :=, <>, var}\}, P, C)$ s produkcijama:
 - 1) $C \rightarrow \text{begin } S_1 \text{ end}$, 3) $S_2 \rightarrow ;S_1$ 5) $S \rightarrow \text{var := var}$
 - 2) $S_1 \rightarrow SS_2$, 4) $S_2 \rightarrow \varepsilon$ 6) $S \rightarrow \text{while var <> var do } S$
 - 7) $S \rightarrow \text{begin } S_1 \text{ end}$
 - tehnikom rekurzivnog spusta programski ostvariti parser
 - za 4 nezavršna znaka imamo 4 potprograma
 - neka je \perp oznaka kraja ulaznog niza w

Parsiranje niza

- TEHNIKA REKURZIVNOG SPUSTA PRIMJER

```
GlavniProgram()
{
    ulaz = čitaj(znak);
    C();
    ako(ulaz =  $\perp$ ) piši ("w  $\in$  L(G)");
    inače piši ("w  $\notin$  L(G)");
}

C()          //produkcija 1)
{
    ako(ulaz <> begin) piši ("w  $\notin$  L(G)");
    ulaz = čitaj(znak);
    S1();
    ako(ulaz <> end) piši ("w  $\notin$  L(G)");
    ulaz = čitaj(znak);
}
```

Parsiranje niza

- TEHNIKA REKURZIVNOG SPUSTA PRIMJER

```
S1()      //produkcija 2)
{
    S();
    S2();
}
```

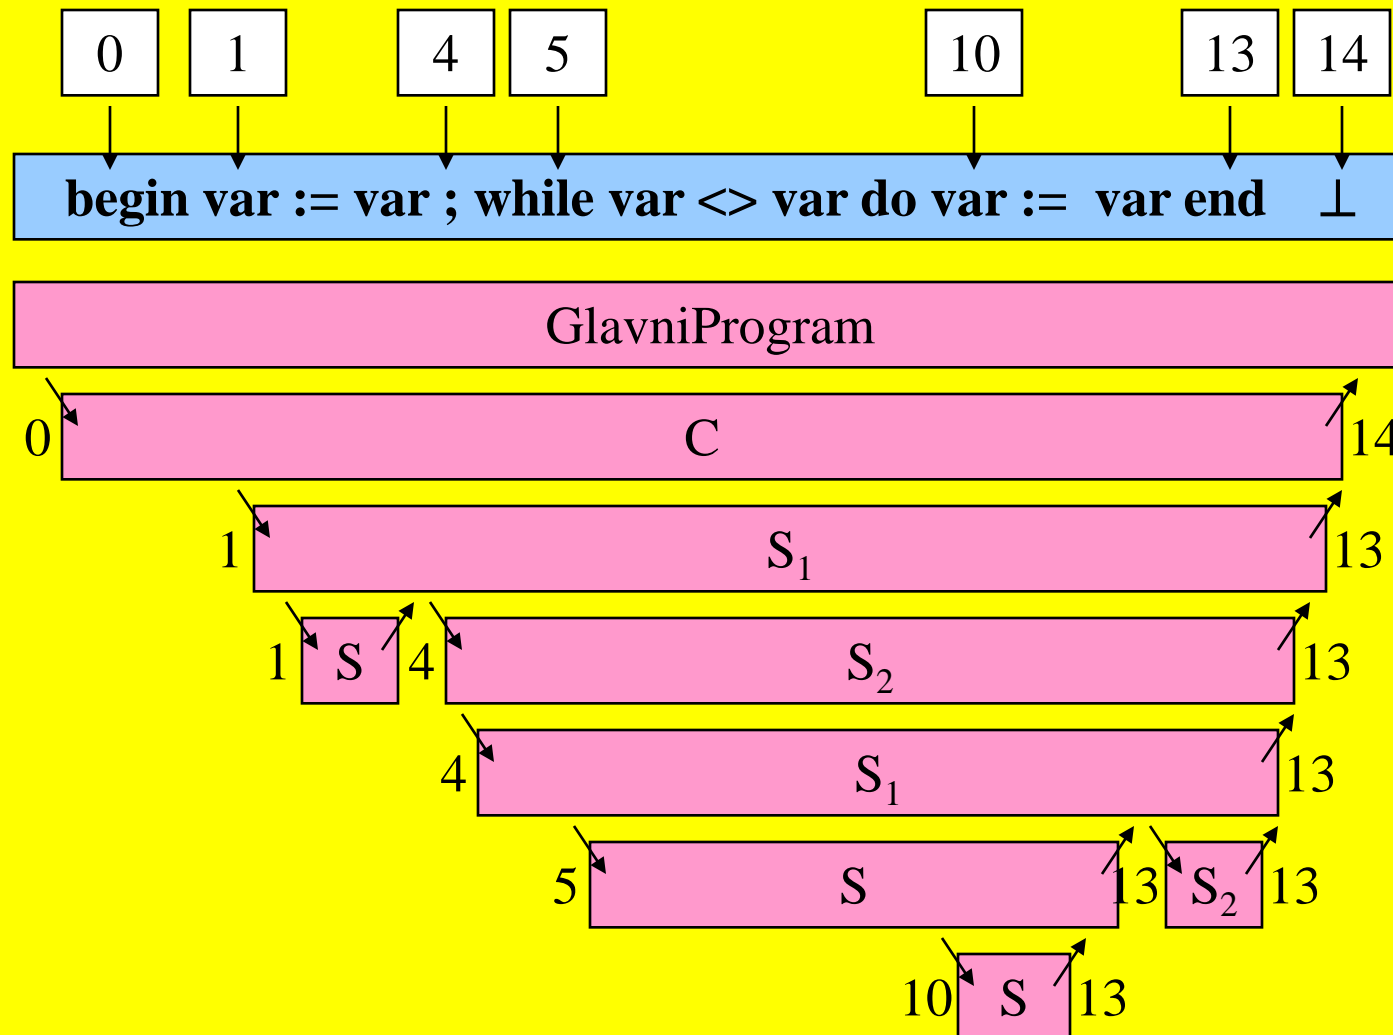
```
S2()      //produkcija 3), i 4) implicitno
{
    ako(ulaz == ;)
    {
        ulaz = čitaj(znak)
        S1()
    }
}
```

- TEHNIKA REKURZIVNOG SPUSTA PRIMJER

```
S()      //produkcije 5), 6) i 7)
{ slučaj(ulaz)
  {var:   ulaz = čitaj(znak)
    ako(ulaz <> :=) piši ("w ∉ L(G)");
    ulaz = čitaj(znak)
    ako(ulaz <> var) piši ("w ∉ L(G)");
    ulaz = čitaj(znak)
    while: ulaz = čitaj(znak)
      ako(ulaz <> var) piši ("w ∉ L(G)");
      ulaz = čitaj(znak)
      ako(ulaz <> <>) piši ("w ∉ L(G)");
      ulaz = čitaj(znak)
      ako(ulaz <> var) piši ("w ∉ L(G)");
      ulaz = čitaj(znak)
      ako(ulaz <> do) piši ("w ∉ L(G)");
      ulaz = čitaj(znak)
      S()
    begin: ulaz = čitaj(znak)
      S1()
      ako(ulaz <> end) piši ("w ∉ L(G)");
      ulaz = čitaj(znak)
    ostalo: piši ("w ∉ L(G)");
  }
}
```

• TEHNIKA REKURZIVNOG SPUSTA PRIMJER

– dijagram pozivanja potprograma za zadani niz



Parsiranje niza

- **PARSER S REKURZIVNIM SPUSTOM**
 - u glavnom programu
 - pročitava se prvi znak niza w
 - pozove se potprogram pridružen početnom nezavršnom znaku
 - provjerava se posljednji očitani znak;
ako je to oznaka kraja niza, niz se prihvata
 - za nezavršni znak gramatike koristi se potprogram
 - ako je više produkcija, za svaku se gradi zasebni dio
 - svaki dio ispituje podniz koji slijedi
 - ako znak pročitani tijekom rada ne odgovara niti jednoj desnoj strani, niz se odbacuje

Parsiranje niza

- **PARSER S REKURZIVNIM SPUSTOM**
 - u dijelu potprograma
 - za svaki završni znak niza ispita se da li odgovara, ako ne odgovara niz se odbacuje
 - za svaki nezavršni znak na krajnjem lijevom mjestu niza poziva se potprogram (bez čitanja niza)
 - za svaki nezavršni znak koji nije na krajnjem lijevom mjestu niza prvo se pročita sljedeći znak, pa se poziva potprogram

Parsiranje niza

- PARSIRANJE OD DNA PREMA VRHU
 - zadana je gramatika $G = (V, T, P, S)$
 - parsiranje započinje sa listovima, odnosno sa završnim znakovima gramatike
 - u nizu w odnosno u dobivenim međunizovima nastoji se prepoznati jedna od desnih strana produkcija
 - ako je dio međuniza jednak desnoj strani produkcije, zamjenjuje se sa lijevom stranom
 - tim zamjenama nastoji se doseći korijen stabla
 - primjena obrnutih produkcija su **redukcije**
 - postupak se koristi u generatorima parsera

Parsiranje niza


- PARSIRANJE OD DNA KA VRHU PRIMJER

- zadana je gramatika $G = (\{E, T, F\}, \{\mathbf{var}, +, *, (,)\}, P, E)$ s produkcijama:

$$1) E \rightarrow E + T \quad 3) T \rightarrow T * F \quad 5) F \rightarrow (E)$$

$$2) E \rightarrow T \quad 4) T \rightarrow F \quad 6) F \rightarrow \mathbf{var}$$

- parsirati niz **var+var*var**
- niz čitamo s lijeva na desno i primijenimo redukciju 6)



$$\mathbf{var+var*var} \Leftarrow F + \mathbf{var*var}$$


Parsiranje niza

- PARSIRANJE OD DNA KA VRHU PRIMJER
 - nadalje jednoznačno primijenimo redukcije 4) 2) 6) 4)

$$F + \text{var} * \text{var} \Leftarrow T + \text{var} * \text{var}$$

$$\Leftarrow E + \text{var} * \text{var}$$


$$\Leftarrow E + T * \text{var}$$



Parsiranje niza

- PARSIRANJE OD DNA KA VRHU PRIMJER

- dalji rad nije jednoznačan,
moguće je primijeniti redukcije 1), 2) ili 6):



$$E+T*\mathbf{var} \Leftarrow E*\mathbf{var}$$

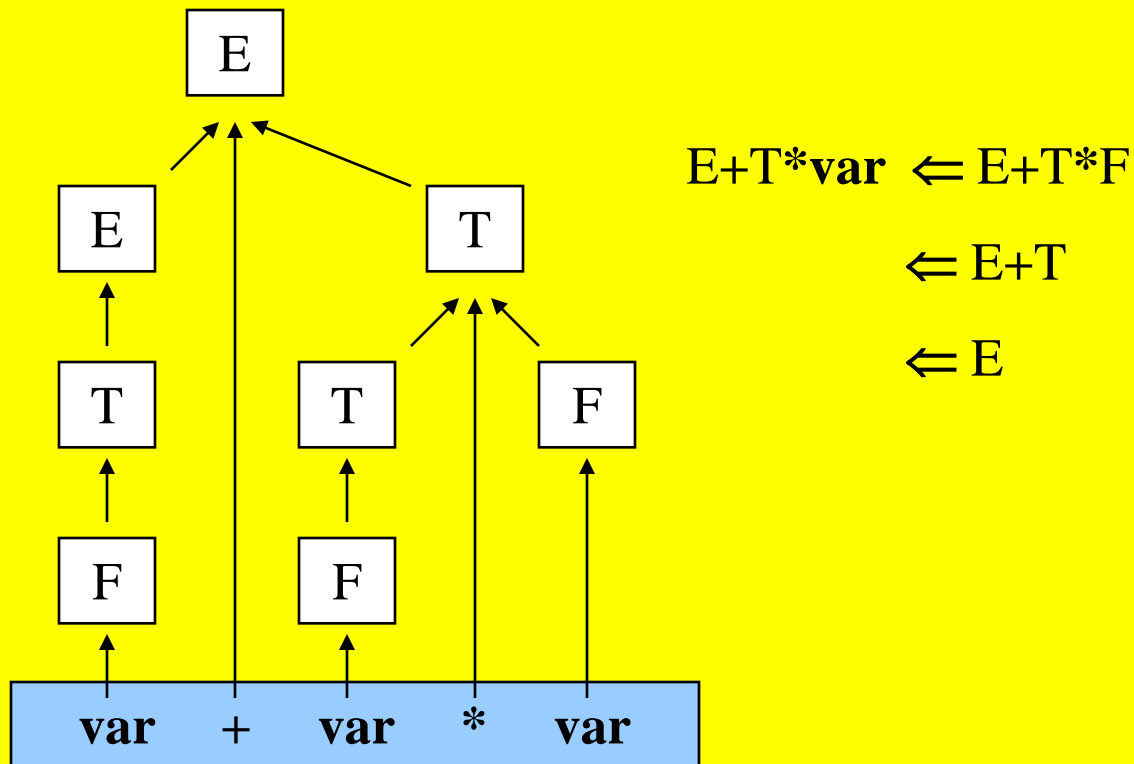
$$\Leftarrow E+E*\mathbf{var}$$

$$\Leftarrow E+T*\mathbf{F}$$

Parsiranje niza

- PARSIRANJE OD DNA KA VRHU PRIMJER

– napredak postizemo redukcijom 6), pa 3) i 1):



Parsiranje niza

- PARSIRANJE OD DNA PREMA VRHU
 - BU parsiranje nije jednoznačno
 - te redukcije su **više značne**
 - izaberemo jednu od višetnačnih redukcija i nastojimo izgraditi generativno stablo
 - ako ne uspijemo, ide se unatrag i pokuša slijedećom od više značnih redukcija
 - postupak **unazadnog pretraživanja** ponavlja se dok se ne ispituju sve više značne mogućnosti
 - uspijemo li izgraditi stablo, niz w je dio jezika $L(G)$
 - učinkovitost ovisi o višeznačnosti

Parsiranje niza

- LR PARSER

- LR(k) parser koristi metodu od dna prema vrhu
 - L: ulazni niz čitamo s lijeva na desno (left to right scanning)
 - R: mijenja krajnje desni nezavršni znak (rightmost derivation)
 - (k): za donošenje odluke potrebno je pročitati najviše k znakova ulaznog niza
- LR(k) je najopćenitiji postupak parsiranja od dna prema vrhu
- provodi se bez unazadnog pretraživanja
- primjenjuje se na široj skup CFG, ali ne na sve
- to su LR gramatike, jer je moguće izgraditi LR parser
- ostale nisu LR gramatike

Parsiranje niza

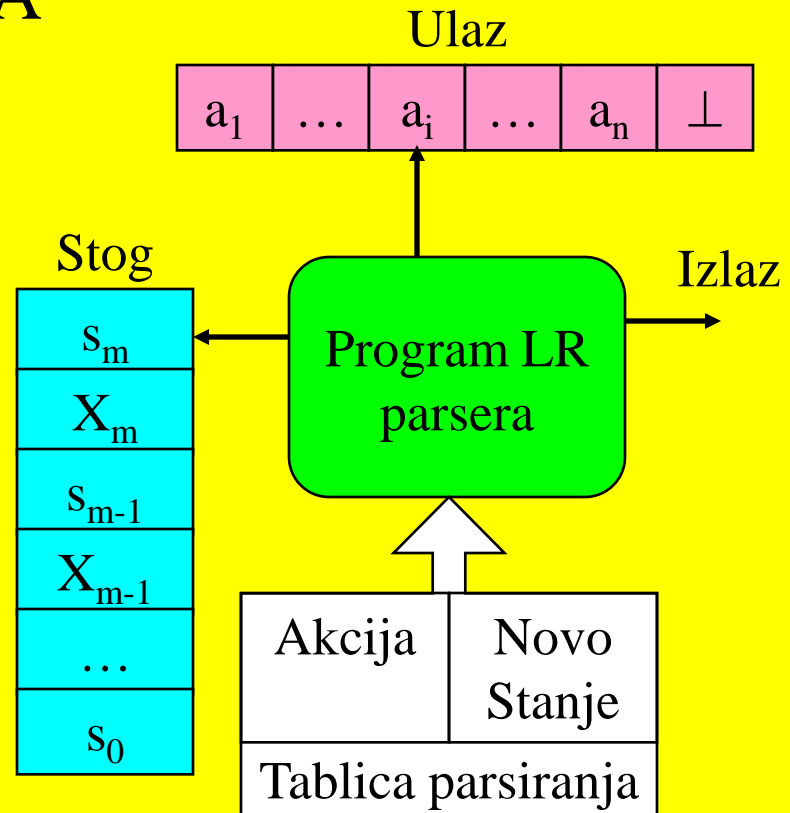
- LR PARSER
 - konstrukcija LR(k) parsera je složena
 - gradi se posebnim generatorom
 - generator koristi skup produkcija
 - postoje različite klase složenosti
 - gradi se tablica parsiranja
 - program parsera je uvijek isti

Parsiranje niza

- MODEL LR PARSERA

- model LR parsera ima

- ulazni spremnik
 - potisni LIFO stog
 - program LR parsera
 - tablicu parsiranja
 - izlaz



Parsiranje niza

- MODEL LR PARSERA

- u stog se sprema niz

$s_0 X_1 s_1 X_2 s_2 \dots X_m s_m$

- s_m je na vrhu stoga
 - X_i su završni ili nezavršni znakovi gramatike
 - s_i su stanja
 - stanje na vrhu stoga s_m jednoznačno određuje sadržaj stoga
 - tijekom rada parser koristi stanja s_i ,
 - znakovi X_i se pamte radi lakšeg praćenja rada


- tablica parsiranja ima dva dijela

- program čita znak a_i i stanje s_m i bira redak tablice parsiranja
 - određuje akciju (Pomak s, Reduciraj $A \rightarrow \beta$, Prihvati, Odbaci)
 - određuje novo stanje

Parsiranje niza

- MODEL LR PARSERA

- spojimo stog i ulazni spremnik u jedinstvenu listu:



- to je **konfiguracija** LR parsera
- ako izuzmemo oznake stanja dobijemo niz:

$$X_1 X_2 \dots X_m , a_i a_{i+1} \dots a_n \perp$$

- to je jedan od međunizova dobiven zamjenom krajnjeg desnog nezavršnog znaka

Parsiranje niza

- MODEL LR PARSERA

- neka je LR parser u konfiguraciji:

$$s_0 X_1 s_1 X_2 s_2 \dots X_m s_m, a_i a_{i+1} \dots a_n \perp$$

- iz tablice se čita Akcija koja mijenja konfiguraciju:

- **Pomak s:** spremi na stog a_i i s , čitaj novi znak:

$$s_0 X_1 s_1 X_2 s_2 \dots X_m s_m a_i s, a_{i+1} \dots a_n \perp$$

- **Reduciraj $A \rightarrow \beta$:** uzmi $2r=2|\beta|$ znakova sa stoga i zamj. A

$$s_0 X_1 s_1 X_2 s_2 \dots X_{m-r} s_{m-r} A s, a_i a_{i+1} \dots a_n \perp$$

- **Prihvati:** prihvaća niz
- **Odbaci:** odbacuje niz

Parsiranje niza

- ALGORITAM LR PARSERA
 - Ulaz: zadani niz w i tablica parsiranja
 - Izlaz: prihvatanje ili neprihvatanje niza
 - Postupak parsiranja:
 - na početku na stogu je početno stanje s_0 a na ulazu niz $w\perp$
 - program se izvodi sve dok se ne dobije izlaz prihvati ili odbaci

• PROGRAM LR PARSERA

```
ProgramLRParsera()
```

```
{ postavi kazaljku na početka niza
```

```
  dok(1)          //ponavljaј zauvijek
```

```
  {slučaj(Akcija[s,a])
```

```
    {Pomak  $s'$ : stavi a na stog
```

```
      stavi  $s'$  na stog
```

```
      pomakni kazaljku
```

```
    Reduciraj  $A \rightarrow \beta$ :
```

```
      uzmi sa stoga  $2*|\beta|$  znakova
```

```
      stavi A na stog
```

```
      stavi NovoStanje[ $s'$ , A] na stog
```

```
    Prihvati: Ispiši("niz prihvaćen");kraj
```

```
    Ostalo:   Ispiši("niz nije prihvaćen");
```

```
      kraj
```

```
  }
```

```
}
```

```
}
```

Parsiranje niza

- PROGRAM LR PARSERA PRIMJER

- zadana je gramatika $G = (\{E, T, F\}, \{\mathbf{var}, +, *, (,)\}, P, E)$ s produkcijama:

$$1) E \rightarrow E + T \quad 3) T \rightarrow T * F \quad 5) F \rightarrow (E)$$

$$2) E \rightarrow T \quad 4) T \rightarrow F \quad 6) F \rightarrow \mathbf{var}$$

- parsirati niz **var+var*var**

Parsiranje niza

• PROGRAM LR PARSERA PRIMJER

– tablica parsera je:

| Stanje | Akcija | | | | | | NovoStanje | | |
|--------|--------|----|----|----|-----|----------|------------|---|----|
| | var | + | * | (|) | ⊥ | E | T | F |
| 0 | s5 | | | s4 | | | 1 | 2 | 3 |
| 1 | | s6 | | | | prihvati | | | |
| 2 | | r2 | s7 | | r2 | r2 | | | |
| 3 | | r4 | r4 | | r4 | r4 | | | |
| 4 | s5 | | | s4 | | | 8 | 2 | 3 |
| 5 | | r6 | r6 | | r6 | r6 | | | |
| 6 | s5 | | | s4 | | | | 9 | 3 |
| 7 | s5 | | | s4 | | | | | 10 |
| 8 | | s6 | | | s11 | | | | |
| 9 | | r1 | s7 | | r1 | r1 | | | |
| 10 | | r3 | r3 | | r3 | r3 | | | |
| 11 | | r5 | r5 | | r3 | r3 | | | |

si - stavi znak i
stanje i na stog
rj - reduciraj
produkcijom j
prihvati- niz je OK
praznini -odbaci
početno stanje je 0

• PROGRAM LR PARSERA PRIMJER

– za niz **var+var*var** imamo transformacije

| Korak | Stog | Ulaz | Akcija |
|-------|-------------------------|---------------------|------------------------------|
| 1. | 0 | var+var*var \perp | pomak 5 |
| 2. | 0 var 5 | +var*var \perp | r F \rightarrow var |
| 3. | 0 F 3 | +var*var \perp | r T \rightarrow F |
| 4. | 0 T 2 | +var*var \perp | r E \rightarrow T |
| 5. | 0 E 1 | +var*var \perp | pomak 6 |
| 6. | 0 E 1 + 6 | var*var \perp | pomak 5 |
| 7. | 0 E 1 + 6 var 5 | *var \perp | r F \rightarrow var |
| 8. | 0 E 1 + 6 F 3 | *var \perp | r T \rightarrow F |
| 9. | 0 E 1 + 6 T 9 | *var \perp | pomak 7 |
| 10. | 0 E 1 + 6 T 9 * 7 | var \perp | pomak 5 |
| 11. | 0 E 1 + 6 T 9 * 7 var 5 | \perp | r F \rightarrow var |
| 12. | 0 E 1 + 6 T 9 * 7 F 10 | \perp | r T \rightarrow T* F |
| 13. | 0 E 1 + 6 T 9 | \perp | r E \rightarrow E+T |
| 14. | 0 E 1 | \perp | prihvati |